

N° d'ordre :/2025/USTM/FS/DMI

DÉPARTEMENT DE MATHÉMATIQUES ET INFORMATIQUE

Laboratoire : Unité de Recherche de Mathématiques et Informatique (URMI)

M E M O I R E D E M A S T E R

Parcours : MASTER DE MATHÉMATIQUES

Option : PROBABILITÉS ET STATISTIQUE

**CLASSIFICATION NON PARAMÉTRIQUE
DE DONNÉES FONCTIONNELLES
SPATIALES SOUS CENSURE ALÉATOIRE**

PAR : BASSINGA MALANDA PASKA YHAVECH

SOUS LA DIRECTION DE : Dr Stéphane BOUKA, Maître de Conférences CAMES

SOUS LA SUPERVISION DE : Pr Guy Martial NKIET, Professeur Titulaire CAMES

Membres du jury :

Président :	Dr Fulgence EYI OBIANG, Maître de Conférences CAMES
Rapporteur :	Dr Alban MBINA MBINA, Assistant
Examineur :	Dr Kowir PAMBO BELLO, Assistant
Encadrant :	Dr Stéphane BOUKA, Maître de Conférences CAMES
Superviseur :	Pr Guy Martial NKIET, Professeur Titulaire CAMES

Soutenu publiquement à Franceville le **02 Octobre 2025**
Année académique : 2024 - 2025

Classification non paramétrique de données fonctionnelles spatiales sous censure aléatoire

Par

BASSINGA MALANDA PASKA YHAVECH

le 2 Octobre 2025



Dédicaces

Je dédie ce mémoire à :

mon défunt père Jean Bassinga,

*mes mamans Ida Clarrisse Banzounzi et Ida Blandine
Bantsimba,*

mon oncle Thomas Makani ainsi qu'à son épouse Antoinnette Makani,

celle qui a rendu ce projet possible Lathy Marth Koumba,



Remerciements :



Remerciements

Je tiens tout d'abord à exprimer ma profonde gratitude à mon directeur de mémoire, le **Docteur Stéphane Bouka**, Maître de conférences CAMES, pour son accompagnement exceptionnel tout au long de ce travail. Sa disponibilité, sa promptitude, son soutien moral et scientifique, ainsi que ses précieux conseils ont été déterminants dans l'aboutissement de ce projet. Son esprit d'innovation et sa persévérance m'ont inspiré, notamment lorsqu'il a su me proposer de nouvelles pistes à explorer aux moments les plus critiques.

J'adresse également mes sincères remerciements au **Professeur Guy Martial Nkiet**, Professeur titulaire CAMES, pour avoir accepté de superviser ce mémoire. Sa rigueur académique, ses conseils avisés et sa passion communicative pour les mathématiques ont grandement nourri ma réflexion et renforcé mon engagement dans cette discipline.

Je souhaite aussi témoigner ma reconnaissance aux membres du jury :

Dr Fulgence Eyi Obiang (Président, Maître de conférences CAMES),

Dr Alban Mbina Mbina (Rapporteur),

Dr Kowir Pambo Bello (Examineur),

Pr Guy Martial Nkiet (Superviseur, Professeur titulaire),

pour avoir honoré ma soutenance de leur présence et pour le temps consacré à l'évaluation de mon travail.

Ma gratitude s'étend à l'ensemble des enseignants et du personnel administratif du **Département de Mathématiques et Informatique** de l'USTM, dont l'engagement et l'expertise ont jalonné mon parcours universitaire. À tous les doctorants du département de mathématiques *Steev, Ibrahim, Rolland, Confort, Lurand* merci pour votre soutien indéfectible, votre disponibilité et vos encouragements. Merci également à mes chers condisciples *Arthur, Dylan, Gidrisca, Arsène, Stéphane, Christ, Josepha, Nze Mba*, pour leurs encouragements et les moments de complicité qui ont illuminé ces années passées à l'USTM. Une pensée amicale à toutes les personnes rencontrées au fil de ce parcours, dont les échanges ont enrichi mon expérience universitaire.

Ma reconnaissance va tout particulièrement à celui qui est pour moi une référence, une source d'inspiration et un mentor : **Thomas Makani**, qui a cru en moi et n'a cessé de me soutenir sur le chemin que j'ai choisi pour vivre ma passion des mathématiques. Je remercie aussi *Sylvain Bazebe, Claude Ntelamani, Richard Tiadiambou, Adolphine Sakanda, Jacqueline Louzoulo, Hiphigénie Makani, D'Avila Basooueka, Marland Ntelamani, et Lyse Bassinga* pour leur soutien financier, moral et leurs encouragements constants.

Enfin, un grand merci à mes amis *Francky Evouna Mintsu, Alan Dewis Ibouanga, Richy*

Iboth pour leurs conseils et leur disponibilité durant les périodes de dur labeur, ainsi qu'au couple *Pendi* pour leur soutien moral et spirituel.



Résumé/ Abstract

Résumé

L'objectif de ce mémoire est d'étudier la consistance du classificateur de Bayes dans un modèle de régression non paramétrique sous censure aléatoire. Pour ce faire, nous procédons d'abord à une transformation des données synthétiques et à la substitution des observations censurées. Nous proposons ensuite un estimateur de la fonction de régression par la méthode des k -plus proches voisins. Des études numériques ont permis d'évaluer la performance du classificateur proposé, dont les résultats confirment la consistance et la validité asymptotique sous les hypothèses de simulation considérées.

Mots-clés : Classificateur de Bayes, transformation de données synthétiques, consistance, censure aléatoire, covariable, données fonctionnelles spatiales, estimation, k -plus proches voisins, régression non paramétrique, substitution.

Abstract

The objective of this thesis is to study the consistency of the Bayes classifier in a non-parametric regression model under random censoring. To achieve this, we first perform a transformation of the synthetic data and imputation of censored observations. Then, we propose an estimator of the regression function using the k -nearest neighbors method. Numerical studies were conducted to evaluate the performance of the proposed classifier, and the results confirm its consistency and asymptotic validity under the considered simulation assumptions.

Keywords : Bayes classifier, synthetic data transformation, consistency, random censoring, covariate, spatial functional data, estimation, k -nearest neighbors, nonparametric regression, substitution.

Table des matières

Dédicaces	i
Remerciements	ii
Abstract / Résumé	v
Introduction générale	1
1 Quelques rappels	3
1.1 Données fonctionnelles	3
1.1.1 Introduction et exemples	3
1.2 Probabilités pour données fonctionnelles	4
1.3 Eléments de statistique descriptive pour les données fonctionnelles	5
1.4 Modèle spatial	7
1.5 Rappel sur les processus stochastiques	8
1.6 Processus stationnaire	9
1.6.1 Définitions, exemples	9
1.7 Processus intrinsèque et variogramme	10
1.7.1 Définition, exemples et propriétés	10
1.7.2 Variogramme d'un processus stationnaire	11
1.7.3 Exemples de variogrammes	11
2 Une note sur la règle des k-plus proches voisins pour les données fonctionnelles spatiales dans un modèle de régression avec réponse scalaire de substitution	12
2.1 Contexte et Problématique	12
2.2 Méthodologie	13
2.3 Résultats	14
3 Analyse de modèles de régression fonctionnelle spatiale sous censure aléatoire	16
3.1 Contexte	16
3.2 Méthodologie d'analyse	17
3.2.1 Test d'absence d'effet	18
3.2.2 Prediction des sites non visités	24
3.3 Résultats	24

4	Classification non paramétrique de données fonctionnelles spatiales sous censure aléatoire	27
4.1	Introduction	27
4.2	Modèle de régression et construction du classificateur	28
4.3	Méthodologie	29
4.4	Étude Numerique	32
4.4.1	Échantillon	32
4.4.2	Hypothèse de simulation	33
4.4.3	Interprétation des trois figures obtenues	33
4.4.4	Choix des paramètres optimaux	34
4.5	Résultats des simulations	36
4.6	Conjecture	37
4.7	Conclusion	37
	Conclusion et Perspectives	38
A	Annexe	41



Introduction générale

Depuis l'avènement des nouvelles technologies, nous assistons à un nombre croissant de collectes de données de grande taille, géo-localisé et avec des composantes dynamiques dans le temps. La particularité de ces données est qu'elles dépendent de l'espace et du temps, nous pouvons en citer quelques exemples comme dans la géologie, les sciences de l'environnement, la finance, la médecine, l'océanographie, l'épidémiologie. En médecine, l'état d'un patient peut-être diagnostiqué grâce à des enregistrements liés au temps (par exemple, électroencéphalogramme, électrocardiogramme), en science de l'environnement, la prévision de la pollution par l'ozone sur les sites non visités comme dans Bouka et al [1], ce qui n'est pas souvent le cas pour des données indépendantes identiquement distribués. On s'intéresse à la classification des covariables fonctionnelles qui sont de nature (des courbes, images, fonctions) consistant à attribuer une observation à une classe parmi plusieurs possibles.

L'analyse fonctionnelle spatiale permet ainsi de construire, entre autres, des méthodes de régression, de classification. Cependant certaines études sont relativement limitées du point de vue théorique et pratique. En plus elles portent en grande partie, sur les modèles paramétriques / semi-paramétriques. La grande dimension de ces types de données pose des défis à la fois théoriques et pratiques qui font que les modèles paramétriques/et semi-paramétriques Menafooglio et al [12], zhang et al [18], ne sont pas adaptés dans ce nouveau contexte spatio-fonctionnel. Par conséquent, la modélisation de ces problèmes complexes fait appel aux modèles de **régression non paramétrique** comme méthodes alternatives surtout lorsque la relation entre les deux variables d'intérêt n'est pas linéaire. Parmi les méthodes non paramétriques existantes l'une des méthodes les plus connues est la méthode **des k-plus proches voisins** proposé par Fix [14], dont la consistance a été établie par Cover et al [5]. Ces approches ne nécessitent pas d'hypothèse fortes sur les distributions et s'adaptent mieux à la complexité des données.

Dans le cadre des données fonctionnelles, la classification non paramétrique a été étendue par Younso [15] avec la règle des k-plus proches voisins pour des données fonctionnelles non spatiales pour la consistance du classificateur de Bayes . Parallèlement, de nombreux phénomènes présentent une dimension spatiale, il est donc nécessaire d'étendre la classification non paramétrique au cas fonctionnel spatial. Des travaux récents, tels que dans Bouka et al [2] ont proposé la règles des k-plus proches voisins adaptée à ce cadre, en utilisant des réponses de substitution, Gollapalli et al [9] ont proposé une approche de classification via l'intelligence artificielle sur les patients atteints de la drépanocytose.

Néanmoins, un aspect peu étudié demeure : la présence de censure aléatoire, fréquente en pratique (par exemple en analyse de survie). [Mokkadem et al \[10\]](#) ont étudié l'estimation de la fonction du Hasard sous censure aléatoire ; [Yang et al \[16\]](#) ont travaillé sur un modèle fonctionnel linéaire sous censure aléatoire chez les patients atteints de l'Alzheimer's ; [Bouka et al \[3\]](#) ont étendu ses travaux dans le cas des données fonctionnelles spatiales dans un modèle de régression fonctionnelle sous censure aléatoire. Malgré ces récents travaux, le problème de classification non paramétrique pour les données fonctionnelles spatiales sous censure aléatoire n'a pas encore été abordé.

Dans ce mémoire, nous proposons une extension de la règle des k-plus proche voisins pour les données fonctionnelles spatiales sous censure aléatoire. Plus précisément nous étudierons la consistance du classificateur de Bayes . Les résultats théoriques obtenus sont validés par des études numériques à travers des méthodes de simulation de Monte-carlo.

Ainsi donc, nous organisons notre travail en quatre chapitres. Dans le Chapitre 1 est un rappel sur quelques notions d'analyse fonctionnelle spatiale il présente quelques bases utiles à la compréhension au travers des définitions ; dans le chapitre 2 nous faisons un résumé étendu sur **une note sur la règle des k-plus proches voisins pour les données fonctionnelles spatiales dans un modèle de régression avec réponse scalaire de substitution** [Bouka et al \[2\]](#) ; dans le chapitre 3 **Analyse de modèles de régression fonctionnelle spatiale sous censure aléatoire** [Bouka et al \[3\]](#) ; dans le chapitre 4 aborde sur **la Classification non paramétrique de données fonctionnelles spatiales sous censure aléatoire** qui constitue notre contribution. Enfin, la dernière partie de notre travail est dédié a l'annexe pour les codes simulé avec le logiciel **R**.

Quelques rappels

Sommaire

1.1	Données fonctionnelles	3
1.1.1	Introduction et exemples	3
1.2	Probabilités pour données fonctionnelles	4
1.3	Eléments de statistique descriptive pour les données fonctionnelles	5
1.4	Modèle spatial	7
1.5	Rappel sur les processus stochastiques	8
1.6	Processus stationnaire	9
1.6.1	Définitions, exemples	9
1.7	Processus intrinsèque et variogramme	10
1.7.1	Définition, exemples et propriétés	10
1.7.2	Variogramme d'un processus stationnaire	11
1.7.3	Exemples de variogrammes	11

1.1 Données fonctionnelles

1.1.1 Introduction et exemples

Les données fonctionnelles sont des observations qui ne sont pas, comme généralement en statistique, des réalisations de variables aléatoires réelles ou vectorielles (vecteurs aléatoires) mais des fonctions aléatoires : courbes, images, etc... Il s'agit de données de dimension infinie, c'est-à-dire rentrant dans le champ de la "très grande dimension". Elles apparaissent de plus en plus fréquemment dans de nombreux domaines scientifiques, grâce aux progrès récents en matière de stockage et traitement des données. Sans chercher l'exhaustivité, la biologie, la climatologie, l'économétrie ou encore la chimie sont susceptibles de produire des données considérées comme des courbes aléatoires.

Quelques exemples.

Études longitudinales. Il est courant de disposer de données concernant un même phénomène mesuré quantitativement à différents temps de mesure. On peut alors souvent

considérer que l'on dispose de courbes aléatoires dépendant du temps (réalisation de processus à temps continu indexés par le temps) :

- courbe des températures relevées en un point donné, à différents instants, courbe des cumuls mensuels de précipitations en un point donné,
- courbe de croissance d'un individu (ou d'une plante) au cours du temps,
- données de biomécanique.

Données fonctionnelles multivariées ou spatiales. Certaines images peuvent être modélisées comme des fonctions aléatoires, dépendant cette fois de deux variables (on peut alors parler de données fonctionnelles multivariées). C'est le cas des données d'écriture manuscrite `handwrit` du package `fda`. Une personne a écrit 20 fois les trois lettres 'fda' et le jeu de données contient les abscisses et ordonnées de la marque du stylo à différents instants d'écriture, pour chacun des tracés.

1.2 Probabilités pour données fonctionnelles

Dans cette partie, $\mathcal{F}$ est un espace de Hilbert séparable de dimension infinie et $(\Omega, \mathcal{A}, \mathbb{P})$ un espace probabilisé.

Définition 1. Variable aléatoire fonctionnelle.

1. On appelle **variable aléatoire fonctionnelle** toute application mesurable $X : \Omega \longrightarrow \mathcal{F}$.

2. On appelle **donnée fonctionnelle** toute réalisation de la variable X .

Exemple Pour $\mathcal{F} = L^2(T)$ l'ensemble des fonctions définies sur un sous-ensemble T de $\mathbb{R}$ à valeurs réelles carré intégrable.

Si $T = [0, 1]$, alors on peut voir une variable fonctionnelle X comme une application $X : \Omega \times [0, 1] \longrightarrow \mathbb{R}$, telle que :

- $\forall \omega \in \Omega$ fixé, la fonction $X(\omega, \cdot) : [0, 1] \longrightarrow \mathbb{R}$ est une trajectoire de X ,

- $\forall t \in [0, 1]$ fixé, la variable aléatoire $X(\cdot, t) : \Omega \longrightarrow \mathbb{R}$ est une variable aléatoire réelle.

Si l'ensemble $T \subset \mathbb{R}$, alors X est une courbe aléatoire; lorsque T est de dimension supérieure, on a un processus aléatoire plus complexe, par exemple une surface aléatoire lorsque $T \subset \mathbb{R}^2$ (une image typiquement).

Dans ce qui suit, il sera question de redéfinir certains outils comme l'espérance et l'opérateur de covariance.

Définition 2. *Espérance mathématique d'une v.a fonctionnelle.*

Soit X une v.a fonctionnelle. L'**espérance** de X est définie comme la fonction non aléatoire $(\mathbb{E}[X])(\cdot)$ (élément de $\mathcal{F}$) définie par :

$$(\mathbb{E}[X])(t) = \mathbb{E}[X(t)] = \int_{\Omega} X(t, \omega) d\mathbb{P}(\omega)$$

Définition 3. *Opérateur de covariance.*

Supposons que $\mathbb{E}[\|X\|^2] < \infty$. L'**opérateur de covariance** de X est défini par

$$\Gamma : f \in \mathcal{F} \longrightarrow \Gamma_f = \mathbb{E}[\langle X - \mathbb{E}[X], f \rangle (X - \mathbb{E}[X])].$$

Il est à valeurs dans $\mathcal{F}$.

Proposition 1. *Supposons que X est une variable aléatoire à valeurs dans un espace de Hilbert séparable $\mathcal{F}$ telle que $\mathbb{E}[\|X\|^2] < \infty$. Alors, l'opérateur de covariance Γ est :*

(i) **autoadjoint** $\forall f, g \in \mathcal{F}, \langle \Gamma f, g \rangle = \langle f, \Gamma g \rangle$

(ii) de **Hilbert-Schmidt** : il existe une base hilbertienne $(\varphi_j)_{j \in \mathbb{N}}$ telle que $\sum_{j \in \mathbb{N}} |\Gamma \varphi_j|^2 < \infty$.

De cette proposition, nous déduisons le corollaire suivant :

Corollaire 1. *Avec les hypothèses et notations de la proposition précédente, l'opérateur de covariance Γ de X est :*

(i) **compact** (l'image de la boule unité de $\mathcal{F}$ par Γ est relativement compact),

(ii) **diagonalisable en base orthonormée**.

1.3 Eléments de statistique descriptive pour les données fonctionnelles

Dans cette partie, nous allons toujours considérer $(\Omega, \mathcal{A}, \mathbb{P})$ un espace probabilisé, $\mathcal{F} = L^2(T)$, avec $T \subset \mathbb{R}$ et X une v.a appartenant à $\mathcal{F}$.

Définition 4. *Echantillon de données fonctionnelles.*

Un échantillon (i.i.d) de données fonctionnelles est un ensemble $\{X_1, \dots, X_n\}$ où $X_i : \Omega \times T \longrightarrow \mathbb{R}, i \in \{1, \dots, n\}$.

Pour manipuler ces données, nous devons :

-penser à discrétiser nos données, c'est-à-dire, considérer la grille de discrétisation $\{t_1, \dots, t_p\} \subset T$ où $p \gg n$,

-présenter nos données sous forme vectorielle, c'est-à-dire, après avoir discrétiser nos données, on obtiendra une matrice $X = (X_i(t_j))_{(i,j) \in \{1, \dots, n\} \times \{1, \dots, p\}}$ qui contient toutes les données.

Définition 5. *Moyenne empirique.*

La **fonction moyenne empirique** de l'ensemble de réalisations $\{X_1, \dots, X_n\}$ de variable de $L^2(T)$ est l'application suivante :

$$\begin{aligned} \bar{X}_n : T &\longrightarrow \mathbb{R} \\ t &\longmapsto \bar{X}_n(t) = \frac{1}{n} \sum_{i=1}^n X_i(t). \end{aligned}$$

Définition 6. *Variance empirique.*

La **variance empirique** de l'ensemble de réalisations $\{X_1, \dots, X_n\}$ de variable de $L^2(T)$ est l'application suivante :

$$\begin{aligned} \text{Var}_n : T &\longrightarrow \mathbb{R} \\ t &\longmapsto \text{Var}_n(t) = \frac{1}{n} \sum_{i=1}^n (X_i(t) - \bar{X}(t))^2. \end{aligned}$$

On définit également l'écart-type comme étant la racine carrée de la fonction variance.

Définition 7. *Fonction de covariance empirique.*

La fonction de **covariance empirique** de l'ensemble de réalisations $\{X_1, \dots, X_n\}$ de variable de $L^2(T)$ est l'application suivante :

$$\begin{aligned} C_n : T^2 &\longrightarrow \mathbb{R} \\ (t_1, t_2) &\longmapsto C_n(t_1, t_2) = \frac{1}{n} \sum_{i=1}^n (X_i(t_1) - \bar{X}(t_1))(X_i(t_2) - \bar{X}(t_2)). \end{aligned}$$

Définition 8. *Opérateur de covariance empirique.*

L'**opérateur de covariance empirique** de l'ensemble de réalisations $\{X_1, \dots, X_n\}$ supposé centré est définie par :

$$\begin{aligned}\Gamma_n : L^2(T) &\longrightarrow L^2(T) \\ f &\longmapsto \frac{1}{n} \sum_{i=1}^n \langle f, X_i \rangle X_i.\end{aligned}$$

où $\forall t \in T, \langle f, X_i \rangle = \int_T f(t) X_i(t) dt$

1.4 Modèle spatial

La statistique spatiale est l'étude des phénomènes observés sur un ensemble $\Lambda_n \subset \mathbb{N}^d$, où ($d \geq 1$), qui peut être un sous espace de $\mathbb{Z}^d$, où de $\mathbb{R}^d$. Les données spatiales font l'objet de modèles et techniques statistiques innovants. Elles sont présentes dans de nombreux domaines tels que l'agronomie, l'économie, les sciences du sol, l'épidémiologie, le géomarketing. La statistique spatiale se différencie de la statistique classique par le fait que les observations sont souvent dépendantes dans l'espace. Il existe trois grands types de données spatiales, à savoir :

1. les données géostatistiques : Les données géostatistiques peuvent être définies sur un ensemble Λ_n qui est un sous-espace continu de $\mathbb{R}^d$. Ces données sont mesurées sur un nombre fini de sites échantillonnés. Le champ $Z = (Z_s, s \in \Lambda_n)$ est observé en n^d sites fixés de Λ_n , ces types de données sont rencontrés dans l'évaluation de la température, les précipitations, l'étude des propriétés des sols, les caractéristiques géologiques, l'évaluation d'une concentration ou de la densité de quelque chose, un comptage d'animaux. Les questions abordées par ces types de données sont les suivantes :

- (a) l'identification et l'estimation du modèle,
- (b) la caractérisation de la variabilité spatiale en fonction de la distance (géographique) entre deux lieux (sites),
- (c) la variable entre les deux points mesurés(ou Krigeage),
- (d) la simulation des variations spatiales du même type,
- (e) l'évaluation de l'erreur d'interpolation et la qualité de l'échantillonnage.

2. les données latituelles : Dans le cas des données sur "latice" ou sur réseau, le champ $Z = (Z_s, s \in \Lambda_n)$ est observé sur un ensemble $\Lambda_n \subset \mathbb{R}^2$ qui est discret et fixé. Les sites représentent en général des unités géographiques d'un réseau structuré à partir d'un graphe de voisinage. Ces types de données se rencontrent dans des données de populations (le pourcentage d'individus du groupe sanguin A dans des régions données), des données épidémiologiques sur un ensemble d'entités administratives (communes, départements), des caractéristiques de villes reliées par un réseau de transport. Les questions qui sont traitées dans ces types de données concernent :

- (a) la caractérisation de la variabilité spatiale,
- (b) l'indépendance entre voisins, régularités,
- (c) l'explication de la distribution des caractéristiques en fonction des distributions dans un voisinage,
- (d) la simulation des distributions spatiales du même type.

3. les processus ponctuels spatiaux : Pour ce type de données, c'est la répartition spatiale des points de l'ensemble $\Lambda_n \subset \mathbb{R}^d$ où ont lieu les observations qui est aléatoire. On dit que cette répartition spatiale est la réalisation aléatoire d'un processus ponctuel Z sur l'ensemble des sites où ont lieu les observations. Un objectif est de savoir si la répartition de l'ensemble des sites est régulière, due au hasard ou si elle présente des agrégats. Ces processus spatiaux sont utilisés pour :

- (a) caractériser la distribution spatiale des objets,
- (b) expliquer la distribution des caractéristiques des objets en fonction de leurs positionnements relatifs,
- (c) simuler des distributions spatiales du même type.

1.5 Rappel sur les processus stochastiques

Considérons $(\Omega, \mathcal{A}, \mathbb{P})$ un espace probabilisé, un espace mesurable $(E, \mathcal{B}(E))$ et $\Lambda_n \subset \mathbb{N}^d$, où $(d \geq 1)$.

Définition 9. *Processus stochastique.*

Un processus stochastique ou aléatoire $(Z_s, s \in \mathbb{N}^d)$ est une collection de variables aléatoires définies sur $(\Omega, \mathcal{A}, \mathbb{P})$ et à valeurs dans $(E, \mathcal{B}(E))$. $(E, \mathcal{B}(E))$ s'appelle l'espace d'état du processus et $\mathbb{N}^d$ l'ensemble (spatial) des sites sur lequel est défini le processus.

Définition 10. *Processus du second ordre.*

$(Z_s, s \in \mathbb{N}^d)$ est un processus (ou champ) du second ordre si, pour tout $s \in \mathbb{N}^d$, le moment d'ordre 2 $(\mathbb{E}[Z_s^2] < \infty)$. La moyenne de Z_s qui existe alors est la fonction $m : \mathbb{N}^d \rightarrow \mathbb{R}$ définie par $m(s) = \mathbb{E}[Z_s]$. La covariance de Z_s est la fonction $c : \mathbb{N}^d \times \mathbb{N}^d \rightarrow \mathbb{R}$ définie pour tous s, t par $c(s, t) = \text{Cov}(Z_s, Z_t)$.

Si $L^2 = L^2(\Omega, \mathcal{A}, \mathbb{P})$ représente l'ensemble des variables aléatoires sur $(\Omega, \mathcal{A})$ à valeurs réelles de carrée intégrable, on notera $Z_s \in L^2$ le fait que Z_s soit un processus du second ordre. Le processus Z_s est dit centré si pour tout $s \in \mathbb{N}^d$, $m = 0$. La propriété caractéristique d'une covariance est d'être semi-définie positive :

$$\forall n \geq 1, \forall a \in \mathbb{R} \text{ et } \forall (s_1, \dots, s_n) \in \mathbb{N}^d : \sum_{i=1}^n \sum_{j=1}^n a_i a_j c(s_i, s_j) \geq 0$$

Cette propriété résulte de la positivité de la variance de toute combinaison linéaire :

$$\text{Var}\left(\sum_{i=1}^n a_i Z_{s_i}\right) = \sum_{i=1}^n \sum_{j=1}^n a_i a_j c(s_i, s_j) \geq 0.$$

On dit que la covariance est définie positive si de plus, pour tout n-uplet de sites distincts, $\sum_{i=1}^n \sum_{j=1}^n a_i a_j c(s_i, s_j) > 0$ dès que $a \neq 0$.

Les processus gaussiens constituent une sous-classe importante des processus de L^2

Définition 11. *Processus gaussien.*

$(Z_s, s \in \mathbb{N}^d)$ est un processus gaussien sur $\mathbb{N}^d$ si, pour toute partie finie $\Lambda \subset \mathbb{N}^d$ et toute suite réelle $a = (a_s, s \in \Lambda)$, $\sum_{s \in \Lambda} a_s Z_s$ est une variable gaussienne.

1.6 Processus stationnaire

Dans cette partie, on supposera que Z est un champs du second ordre de moyenne m et de covariance c sur $\Lambda_n \subset \mathbb{R}^d$ ou $\mathbb{Z}^d$.

1.6.1 Définitions, exemples

Définition 12. *Champ stationnaire du second ordre.*

Z est un champ stationnaire du second ordre, si la moyenne de Z est constante et si la covariance de Z est invariante par translation :

$\forall s, t \in \Lambda_n : \mathbb{E}[Z] = m$ et $c(s, t) = \text{Cov}(Z_s, Z_t) = C(t - s)$. $C : \Lambda_n \rightarrow \mathbb{R}$ est la fonction de covariance stationnaire de Z . L'invariance par translation de c se produit par :

$$\forall s, t, h \in \Lambda_n : c(s + h, t + h) = \text{Cov}(Z_{s+h}, Z_{t+h}) = C(t - s).$$

La fonction de corrélation de Z est la fonction $h \rightarrow \rho(h) = C(h)/C(0)$. On a alors les propriétés suivantes :

Proposition 2. *Soit Z un processus stationnaire du second ordre de covariance stationnaire C , alors :*

1. $\forall h \in \Lambda_n, |C(h)| \leq C(0) = \text{Var}(Z_s)$
2. $\forall k \geq 1, \forall a \in \mathbb{R}^n$ et $\{s_1, \dots, s_n\} \in \Lambda_n : \sum_{i=1}^k \sum_{j=1}^k a_i a_j C(t - s) \geq 0$.
3. Si $C_1, C_2, \dots$ sont des covariances stationnaires, les fonctions suivantes le sont aussi :

(a) $C(h) = a_1 C_1(h) + a_2 C_2(h)$ si a_1 et $a_2 \geq 0$;

(b) $C(h) = C_1(h)C_2(h)$

Deux notions encadrent la notion de stationnaire dans L^2 . L'une, plus faible et qui sera présentée à la section suivante, est celle de processus à accroissement stationnaires, ou processus intrinsèque. L'autre plus forte est la stationnarité stricte, Z est stationnaire au sens strict si la loi du processus est invariante par translation. Si Z est stationnaire au sens strict et si $Z \in L^2$ alors Z est stationnaire dans L^2 . L'inverse n'est pas vrai en général mais les deux notions coïncident si Z est un processus gaussien stationnaire dans L^2 .

Exemple Bruit Blanc Fort(BBF), Bruit Blanc faible(BBf)

Z est un BBF si les variables $\{Z_s, s \in \Lambda_n\}$ sont centrées, indépendantes et identiquement distribuées(i.i.d). Z est un BBf si les variables $\{Z_s, s \in \Lambda_n\}$ sont centrées, décorréées et de variances finies constantes : si $s \neq t$. $Cov(Z_s, Z_t) = 0$ et $Var(Z_s) = \sigma^2 < \infty$. Un BBF sur Λ_n est strictement stationnaire ; un BBf sur Λ_n est un processus stationnaire dans L^2 . Nous noterons $\|\cdot\|$ la norme euclidienne sur $\mathbb{R}^d$.

Définition 13. *Covariance isotropique.*

La covariance de Z est isotropique si pour tout $s, t \in \Lambda_n$, $Cov(Z_s, Z_t)$ ne dépend que de $\|s - t\|$: $\exists C_0 : \mathbb{R}^+ \rightarrow \mathbb{R}$ tel que $:s, t \in \Lambda_n, c(s, t) = C_0(\|s - t\|) = C(s - t)$.

1.7 Processus intrinsèque et variogramme

1.7.1 Définition, exemples et propriétés

Définition 14. *Processus intrinsèque.*

Z est un processus intrinsèquement stationnaire, ou encore Z est un processus intrinsèque, si pour tout $h \in \Lambda_n$, le processus $\Delta Z^{(h)} = \{\Delta Z_s^{(h)} = Z_{s+h} - Z_s : s \in \Lambda_n\}$ est stationnaire du second ordre. Le sémi-variogramme de Z est la fonction $\gamma : \Lambda_n \rightarrow \mathbb{R}$ définie par :

$$2\gamma(h) = Var(Z_{s+h} - Z_s)$$

Tout processus stationnaire de L^2 de covariance C est clairement un processus intrinsèque de variogramme $2\gamma(h) = 2(C(0) - C(h))$. Mais la réciproque est fausse.

Proposition 3. *Propriétés du variogramme.*

1. $\gamma(h) = \gamma(-h)$, $\gamma(h) \geq 0$ et $\gamma(0) = 0$

2. Un variogramme est conditionnellement défini négatif, c'est-à-dire

$\forall a \in \mathbb{R}^n / \sum_{i=1}^k a_i = 0, \forall \{s_1, \dots, s_n\} \in \Lambda_n$ on a :

$$\sum_{i=1}^k \sum_{j=1}^k a_i a_j \gamma(s_i - s_j) \leq 0.$$

3. Les propriétés 3-(a,b) d'une covariance (cf.Prop. 1.6) se maintiennent pour un variogramme.

4. Si γ est borné au voisinage de 0, $\exists a$ et $b \geq 0$ tels que pour tout $x : \gamma(x) \neq a \|x\|^2 + b$.

1.7.2 Variogramme d'un processus stationnaire

Si Z est stationnaire de covariance C , alors Z est intrinsèque de variogramme : $2\gamma(h) = 2(C(0) - C(h))$.

Les méthodes statistiques pour les processus stationnaires du second ordre peuvent être traduites en terme de covariance ou en terme de variogramme.

1.7.3 Exemples de variogrammes

Il existe différents types de variogrammes isotropiques. Nous citons ici les variogrammes isotropiques associés à une covariance stationnaire $C(h) = C(0) - \gamma(h)$. En voici quelques exemples :

1. Péritique : $\gamma(h) = \sigma^2$ si $h > 0, \gamma(0) = 0$

2.Exponentiel : $\gamma(h) = \sigma^2 \{1 - \exp(-\|h\|/a)\}$

3.Exponentiel généralisé, gaussien : $\gamma(h) = \sigma^2 \{1 - \exp(-\|h\|/a)^\alpha\}$, si $0 < \alpha \leq 2$; le cas $\alpha = 2$ est le modèle gaussien.

Une note sur la règle des k-plus proches voisins pour les données fonctionnelles spatiales dans un modèle de régression avec réponse scalaire de substitution

Sommaire

2.1	Contexte et Problématique	12
2.2	Méthodologie	13
2.3	Résultats	14

Dans ce chapitre, nous faisons un résumé des résultats des travaux de Bouka et al [2] intitulé Une note sur la règle des k-plus proches voisins pour les données fonctionnelles spatiales dans un modèle de régression avec réponse scalaire de substitution.

2.1 Contexte et Problématique

Soit $(Y_i, X_i)_{i \in I_n}$ un échantillon spatial, où $n = (n_1, \dots, n_d)$,

$$I_n = \{\mathbf{i} = (i_1, \dots, i_d) \in \mathbb{N}^d : 1 \leq i_\ell \leq n_\ell, \ell = 1, \dots, d\}$$

est une grille spatiale, Y_i est une variable aléatoire réelle et X_i est une variable aléatoire fonctionnelle définie sur un espace probabilisé $(\Omega, \mathcal{F}, \mathbb{P})$, à valeurs dans un espace métrique séparable $(\mathcal{E}, \varphi)$, où $\mathcal{E}$ est un espace fonctionnel et φ est la métrique sur $\mathcal{E}$. On suppose que (Y_i, X_i) a la même distribution $(\rho, \mathcal{E})$ qu'un vecteur aléatoire (Y, X) , où $\rho(A) = \mathbb{P}(X \in A)$ est la mesure de probabilité pour tout borélien $A \in \mathcal{E}$.

Soit le modèle de régression générale binaire définit par :

$$\xi(x) = \mathbb{E}(g(Y)|X = x), \forall x \in \mathcal{E} \quad (2.1)$$

où $g : \mathbb{R} \rightarrow \{0, 1\}$ est une transformation binaire de la variable aléatoire de réponse réelle Y .

On considère l'erreur de classificateur de Bayes qui est la plus petite erreur de se tromper de classe défini par :

$$L = L(f) = \inf_{f: \mathcal{E} \rightarrow \{0,1\}} \mathbb{P}(f(X) \neq g(Y)) \quad (2.2)$$

et son classificateur de Bayes qui est une application mesurable $f: \mathcal{E} \rightarrow \{0,1\}$ telle que :

$$f(x) = \mathbb{1}_{\{\xi(x) \geq \frac{1}{2}\}} \quad (2.3)$$

qui est en pratique le meilleur classificateur.

Soit $\xi_n(x)$ l'estimateur de $\xi(x)$, alors $f_n(x)$ est déduit en introduisant $\xi_n(x)$, $f_n(x)$ est le classifieur des k-plus proches voisins qui sera introduit dans la suite. Pour l'estimation de la fonction de régression $\xi(x)$, les auteurs utilisent **l'approche des k-plus proches voisins. Le but de cet article est d'évaluer les propriétés asymptotiques de l'estimateur de l'erreur de classification de l'estimateur du classificateur de Bayes obtenues à partir des données spatiales.** Soit L_n l'estimateur de L , ses propriétés asymptotiques sont :

- consistance simple si : $\lim_{n \rightarrow +\infty} \mathbb{E}[L_n] = L$
- consistance forte si : $\mathbb{P}(\lim_{n \rightarrow +\infty} L_n = L) = 1$

2.2 Méthodologie

Dans cette section, on s'intéresse à l'estimation de la fonction de régression générale binaire $\xi(x)$ afin de déduire $f_n(x)$ l'estimateur du classifieur de $f(x)$ en introduisant $\xi_n(x)$ l'estimateur de $\xi(x)$ et L_n l'estimateur de l'erreur de classification de L . Cependant, dans le modèle de régression générale binaire $\xi(x)$, certaines observations de la variable aléatoire réponse réelle Y sont manquants, au lieu de supprimer les données manquantes les auteurs les substituent par un noyau de pondération, et l'estimation de $\xi(x)$ par l'approche des k-plus proches voisins.

Avant de faire toutes estimations les auteurs utilisent **un ordre lexicographique** qui est un ordre défini sur les séquences finies d'éléments d'un ensemble ordonné i.e $(i_1, \dots, i_d) < (j_1, \dots, j_d) \iff \exists l \in \{1, \dots, d\}, i_l < j_l$ où $i_k = j_k \forall k < l$ et $i_l < j_l$. En utilisant l'ordre lexicographique, ils réécrivent les données d'apprentissages de la sorte :

$$D_{\mathbf{V}} = \{(Y_{i_1}, X_{i_1}), \dots, (Y_{i_l}, X_{i_l}), \dots, (Y_{i_d}, X_{i_d})\}.$$

où $D_{\mathbf{V}}$ représente l'ensemble des données manquantes .

Par conséquent la fonction de régression $g(Y)$ étant donné $X = x$ peut s'écrire :

$$\xi(x) = \mathbb{E}[\mathbb{E}(g(Y)|X, \tilde{Y})|X = x], \forall x \in \mathcal{E} \quad (2.4)$$

,où $\tilde{Y}$ est une variable de substitution de Y , alors l'échantillon devient :

$$D_{\mathbf{n}} = \{(g(Y_{i_1}), X_{i_1}), \dots, (g(\tilde{Y}_{i_j}), X_{i_j}), \dots, (g(Y_{i_d}), X_{i_d})\}.$$

les auteurs utilisent une approche **des k-plus proches voisins avec un noyau de pondération** pour estimer les valeurs manquantes de Y définie par :

$$U(\tilde{Y}_{i_j}, X_{i_j}) = \sum_{i_l \in \mathbf{V}} g(Y_{i_l}) W_{2,n,i_l}(\tilde{Y}_{i_j}, X_{i_j}), \quad \forall j \in \tilde{V} \quad (2.5)$$

$$= \sum_{i_l \in \mathbf{V}} g(Y_{i_l}) \frac{\mathbb{1}_{\{X_{i_l} \in B_{X_{i_j}, r_n}\}} K\left(\frac{Y_{i_l} - \tilde{Y}_{i_j}}{h}\right)}{\sum_{i_l \in \mathbf{V}} \mathbb{1}_{\{X_{i_l} \in B_{X_{i_j}, r_n}\}} K\left(\frac{Y_{i_l} - \tilde{Y}_{i_j}}{h}\right)} \quad (2.6)$$

où $W(.,.) = K(.)K(.)$ est le produit de deux noyau dont l'indicatrice gère la structure spatiale des voisins dans la boule et l'autre gère la similarité entre la donnée existante et celle substituer, avec $\mathbf{V} \cup \tilde{V} = \mathcal{I}_n$, $\mathbf{V} \cap \tilde{V} = \emptyset$, $\tilde{V}$ est le complémentaire de $\mathbf{V}$ i.e les observations complétées à partir de celle manquantes dans $\mathbf{V}$, $m = \text{Card}(\mathbf{V})$, $h = h_n \searrow 0$ lorsque $n \rightarrow +\infty$ $\{i.e., \min_{l=1,\dots,d} \{n_l\} \rightarrow +\infty\}$ h est la fenêtre, K est le noyau a support compact, $\mathbb{1}_A$ et $B_{x,r}$, sont respectivement, la fonction indicatrice de A et la boule fermé de rayon $r > 0$ et de centre $x \in \mathcal{E}$, $r_n = r_n(x) \rightarrow 0$ lorsque $n \rightarrow +\infty$, on a :

$$\rho(B_{x,r_n}) \geq \sqrt{\frac{k}{\hat{n}}} \quad (2.7)$$

, où $\hat{n} = n_1 \times \dots \times n_d$, k est le nombre de voisins de $x \in D_n$. Ainsi, l'estimation par la méthode des k-plus proche voisins de la fonction de régression $\xi(x)$ est obtenue à partir des données complètes et substituées telle que :

$$\xi_n(x) = \sum_{i_l \in \mathbf{V}} g(Y_{i_l}) W_{n,i_l} + \sum_{i_j \in \tilde{\mathbf{V}}} U(\tilde{Y}_{i_j}, X_{i_j}) W_{n,i_j} \quad (2.8)$$

$$= \frac{\sum_{i_l \in \mathbf{V}} g(Y_{i_l}) \mathbb{1}_{\{X_{i_l} \in B_{x,r_n}\}}}{\hat{n}\rho(B_{x,r_n})} + \frac{\sum_{i_j \in \tilde{\mathbf{V}}} U(\tilde{Y}_{i_j}, X_{i_j}) \mathbb{1}_{\{X_{i_j} \in B_{x,r_n}\}}}{\hat{n}\rho(B_{x,r_n})} \quad (2.9)$$

où $W_{n,i} = \frac{\mathbb{1}_{\{X_i \in B_{x,r_n}\}}}{\hat{n}\rho(B_{x,r_n})}$ est l'approche des k-plus proches voisins pondéré.

Alors l'estimateur du classificateur de Bayes des k-plus proches voisins est déduis par :

$$f_n(x) = \begin{cases} 0 & \text{si } \xi_n(x) \leq \frac{1}{2}, \\ 1 & \text{sinon,} \end{cases} \quad (2.10)$$

et son estimateur d'erreur de classification des k plus proches voisins est :

$$L_n = \mathbb{P}(f_n(x) \neq g(Y)) \quad (2.11)$$

2.3 Résultats

Dans cette section, il est question de reporter certains résultats de cet article.

Le théorème suivant donne une borne d'échantillon fini pour la variance de ξ_n .

Théorème 1. *Sous certaines hypothèses, $\forall x \in \mathcal{E}$ on a :*

$$Var(\xi_{\mathbf{n}}(x)) = O\left(\frac{m}{\widehat{\mathbf{n}}\sqrt{k\widehat{\mathbf{n}}}}\right) + O\left(\frac{(\widehat{\mathbf{n}} - m)}{\widehat{\mathbf{n}}\sqrt{k\widehat{\mathbf{n}}}}\right) + O\left(\sqrt{\frac{m(\widehat{\mathbf{n}} - m)}{k\widehat{\mathbf{n}}^3}}\right)$$

les corollaires suivants établissent les propriétés asymptotiques de l'estimateur de l'erreur de classification.

Corollaire 1. *Sous les hypothèses du **Théorème 1** on a : l'estimateur L_n de l'erreur de classification est consistant.*

Corollaire 2. *Sous les hypothèses du **Théorème 1** et $k/\log(\widehat{\mathbf{n}}) \rightarrow +\infty$ on a : l'estimateur L_n de l'erreur de classification est fortement consistant*

.

CHAPITRE

3 Analyse de modèles de régression fonctionnelle spatiale sous censure aléatoire

Sommaire

3.1	Contexte	16
3.2	Méthodologie d'analyse	17
3.2.1	Test d'absence d'effet	18
3.2.2	Prediction des sites non visités	24
3.3	Résultats	24

Dans ce chapitre, il est question de faire un résumé étendu sur les travaux de Bouka et al [3] intitulé : **Analyse de modèles de régression fonctionnelle spatiale sous censure aléatoire**

3.1 Contexte

Soit $(Y_i, X_i)_{i \in I_n}$ un échantillon spatial, où $I_n = \{1, \dots, n\}^N$ avec $N \geq 2$ et $\mathbf{n} = (n, \dots, n) \in \mathbb{N}^N$, Y_i est une variable aléatoire réelle et X_i est une variable aléatoire fonctionnelle de carré intégrable. Cependant, dans la pratique, les données Y_i ne sont pas toutes observables en raison d'une censure aléatoire (qui peut être liée à une contrainte telle que la vraie concentration d'ozone ne doit pas dépassé 60 - 100 $\mu g m^3$). Soit $C_i, i \in I_n$, des variables aléatoires censurées à droite. On suppose que $\{Y_i, i \in I_n\}$ et $\{C_i, i \in I_n\}$ sont indépendantes. Les données censurées à droite sont les paires $\{Z_i, \delta_i\}_{i \in I_n}$ définie par :

$$Z_i = \min \{Y_i, C_i\}, \delta_i = \mathbb{1}_{Y_i \leq C_i}. \quad (3.1)$$

On considère le modèle de régression linéaire fonctionnelle où une variable aléatoire fonctionnelle spatiale $X_i(t)$ de carré intégrable est liée à une variable spatiale réelle censurée Z_i , définie par :

$$Z_i = \langle \Psi, X_i \rangle_G + \xi_i, i \in I_i \subseteq \mathbb{N}^N \quad (3.2)$$

où $G =: L^2([0, 1])$ l'espace des fonctions de carré intégrable avec la norme $\|\cdot\|_G$ associé au produit scalaire $\langle \cdot, \cdot \rangle_G$ défini par $\langle x, y \rangle_G = \int_0^1 x(t)y(t) dt$, et $\Psi \in G = L^2([0, 1])$ est

une fonction de pente .On suppose que ξ_i et X_i sont des variables aléatoires centrées¹ et indépendantes²

Dans cet article les auteurs s'intéressent à tester l'hypothèse nulle d'absence d'effet à partir des données spatialement dépendantes, et la prédiction à des sites non visités i.e Soit $\widehat{\Psi}$ l'estimateur de Ψ , la prédiction à des sites non visités $i_0 \in \mathbb{N}^N$ est défini par :

$$\widehat{Y}_{i_0}^M = \langle \widehat{\Psi}, X_{i_0} \rangle \text{ et } Y_{i_0}^{*M} = \langle \Psi, X_{i_0} \rangle$$

,respectivement $\widehat{Y}_{i_0}^M$ et $Y_{i_0}^{*M}$ définissent la prédiction empirique et théorique.Plus précisément, il est questions de vérifier que le risque quadratique converge vers 0,c'est à dire :

$$R(\widehat{Y}_{i_0}^M, Y_{i_0}^{*M}) = \mathbb{E} \left[\left(\widehat{Y}_{i_0}^M - Y_{i_0}^{*M} \right)^2 \right] \longrightarrow 0.$$

3.2 Méthodologie d'analyse

Dans cette section,on s'intéresse a deux principales étapes de la méthodologie. En premier lieu **tester l'hypothèse nulle d'absence d'effet du covariable à partir des données spatialement dépendant** c'est-à-dire savoir si la covariable X_i à un effet significative sur la variable réponse Z . Deuxièmement, **la prédiction a des sites non visités**.

Cependant, dans la variable réponse Z_i certaines données ne sont pas observables en présence de la censure. Pour y remédier, il existe plusieurs méthodes de substitution pour des données censurées, dans cet article les auteurs utilisent une approche par la transformation des données synthétiques définie par :

$$Y_i^M = \int_0^{Z_i} \frac{1}{1 - M_C(s)} ds,$$

où $M_C(.)$ désigne la fonction de répartition de la variable de censure C_i ,satisfaisant $M_C(0) = 0$ et $M_C(Z_i) \leq \frac{1}{2}$ (c'est-à-dire que le taux de censure est supposé être inférieur à 50%, pour une validité théorique).Sous la transformation,ils obtiennent :

$$\mathbb{E}(Y_i^M | X_i(.)) = \mathbb{E}(Z_i | X_i(.)) \quad (3.3)$$

1. $\mathbb{E}(X_i) = 0$ et $\mathbb{E}(\xi_i) = 0$

2. $\mathbb{E}(\xi_i X_i) = \mathbb{E}(\xi_i) \mathbb{E}(X_i)$

on a $\forall x \in \mathbb{R}$:

$$\mathbb{E}(Y_i^M | X_i = x) = \mathbb{E} \left[\int_0^{Z_i} \frac{1}{1 - M_C(s)} ds | X_i = x \right], \text{ en utilisant Fubini} \quad (3.4)$$

$$= \int_0^{+\infty} \mathbb{E} \left[\mathbb{1}_{\{s \leq Z_i\}} \frac{1}{1 - M_C(s)} | X_i = x \right] ds, \quad (3.5)$$

$$= \int_0^{+\infty} \mathbb{E} \left[\mathbb{1}_{\{s \leq Y_i\}} \mathbb{1}_{\{s \leq C_i\}} \frac{1}{1 - M_C(s)} | X_i = x \right] ds \quad Y_i \text{ et } C_i \text{ sont indépendants} \quad (3.6)$$

$$= \int_0^{+\infty} \mathbb{E} [\mathbb{1}_{\{s \leq Y_i\}} | X_i = x] \mathbb{E} [\mathbb{1}_{\{s \leq C_i\}} | X_i = x] \frac{1}{1 - M_C(s)} ds \quad (3.7)$$

$$= \int_0^{+\infty} \mathbb{P}(Y_i \geq s | X_i = x) \frac{\mathbb{P}(C_i \geq s | X_i = x)}{1 - M_C(s)} ds, \quad X_i \text{ et } C_i \text{ sont indépendants} \quad (3.8)$$

$$= \int_0^{+\infty} \mathbb{P}(Y_i \geq s | X_i = x) \frac{\mathbb{P}(C_i \geq s)}{1 - M_C(s)} ds \quad (3.9)$$

$$= \int_0^{+\infty} \mathbb{P}(Y_i \geq s | X_i = x) \frac{\mathbb{P}(C_i \geq s)}{\mathbb{P}(C_i \geq s)} ds \quad (3.10)$$

car $\mathbb{P}(C_i \geq s | X_i = x) = \mathbb{P}(C_i \geq s)$ et $1 - M_C(s) = \mathbb{P}(C_i \geq s)$

on obtient finalement $\forall x \in \mathbb{R}$:

$$\mathbb{E}[Y_i^M | X_i = x] = \int_0^{+\infty} \mathbb{P}(Y_i > s | X_i = x) ds = \mathbb{E}[Y_i | X_i = x] = \mathbb{E}[Z_i | X_i = x] \quad (3.11)$$

Cela montre que Y_i^M et Z_i sont équivalents en termes d'espérance conditionnelle, Y_i^M devient une variable de réponse de substitution valide dans le modèle de régression linéaire fonctionnelle.

Cependant, puisque la réponse synthétique Y_i^M dépend de la fonction de répartition de censure inconnue $M_C(\cdot)$, elle doit être estimée à partir des données. Si la variable aléatoire de censure est indépendant des covariables, l'estimateur de Kaplan-Meier est un choix approprié. Inversement, lorsque la censure dépend des covariables, un estimateur $\widehat{M}_C(s)$ peut être obtenu en utilisant le modèle de régression de Cox.

Dans cet article les auteurs restent dans un cadre plus général, en considérant un estimateur empirique de la variable de réponse substitut synthétique résultante est alors donnée par :

$$Y_i^{\widehat{M}} = \int_0^{Z_i} \frac{1}{1 - \widehat{M}_C(s)} ds. \quad (3.12)$$

3.2.1 Test d'absence d'effet

Dans cette sous-section, une fois que la variable réponse de censure a été substituée, les auteurs s'intéressent aux tests d'hypothèse nulle d'absence d'effet des covariables en utilisant les données spatialement dépendants c'est-à-dire entre deux hypothèses concurrentes :

$$H_0 : \Psi = 0, \text{ contre } H_1 : \Psi \neq 0. \quad (3.13)$$

Pour résoudre ce problème de test, les auteurs proposent deux statistiques de test telle que :

$$\begin{aligned} D_{\mathbf{n}} &= \frac{1}{\widehat{\sigma}^2} \|n^{N/2} \overline{\Delta_{\mathbf{n}}} \widehat{B}_{\mathbf{n}}\|_{\mathcal{HS}}^2 \\ &= \frac{1}{\widehat{\sigma}^2} \|n^{N/2} \frac{1}{n^N} \sum_{\mathbf{i} \in I_n} Y_{\mathbf{i}}^{\widehat{M}} \langle X_i, x \rangle_G \sum_{j=1}^{Q_{\mathbf{n}}} \widehat{\lambda}_j^{-1/2} \langle \widehat{v}_j, \cdot \rangle_G \widehat{v}_j\|_{\mathcal{HS}}^2 \\ &= \frac{1}{\widehat{\sigma}^2} \|n^{-N/2} \sum_{\mathbf{i} \in I_n} Y_{\mathbf{i}}^{\widehat{M}} \langle X_i, \widehat{v}_j \rangle_G \widehat{v}_j \sum_{j=1}^{Q_{\mathbf{n}}} \widehat{\lambda}_j^{-1/2}\|_{\mathcal{HS}}^2 \\ &= \frac{1}{\widehat{\sigma}^2} \sum_{k=1}^{+\infty} \left(n^{-N/2} \sum_{\mathbf{i} \in I_n} Y_{\mathbf{i}}^{\widehat{M}} \langle X_i, \widehat{v}_j \rangle_G \sum_{j=1}^{Q_{\mathbf{n}}} \widehat{\lambda}_j^{-1/2} \right)^2 \langle \widehat{v}_j, \widehat{v}_k \rangle_G \\ &= \frac{1}{\widehat{\sigma}^2 n^N} \sum_{k=1}^{+\infty} \sum_{j=1}^{Q_{\mathbf{n}}} \widehat{\lambda}_j^{-1} \left(\sum_{\mathbf{i} \in I_n} Y_{\mathbf{i}}^{\widehat{M}} \langle X_i, \widehat{v}_j \rangle_G \right)^2 \langle \widehat{v}_j, \widehat{v}_k \rangle_G \end{aligned}$$

Les fonctions propres $\widehat{v}_j$ de l'opérateur de covariance empirique $\Gamma_{\mathbf{n}}$ sont orthonormales dans l'espace G , donc :

$$\langle \widehat{v}_j, \widehat{v}_k \rangle_G = \delta_{jk} = \begin{cases} 1 & \text{si } j = k, \\ 0 & \text{sinon.} \end{cases}$$

on a par la suite

$$\begin{aligned} D_{\mathbf{n}} &= \frac{1}{\widehat{\sigma}^2 n^N} \sum_{j=1}^{Q_{\mathbf{n}}} \widehat{\lambda}_j^{-1} \left(\sum_{\mathbf{i} \in I_n} Y_{\mathbf{i}}^{\widehat{M}} \langle X_i, \widehat{v}_j \rangle_G \right)^2 \\ &= \frac{1}{\widehat{\sigma}^2 n^N} \sum_{j=1}^{Q_{\mathbf{n}}} \widehat{\lambda}_j^{-1} \left(\sum_{\mathbf{i} \in I_n} Y_{\mathbf{i}}^{\widehat{M}} \int_0^1 X_i(t) \widehat{v}_j(t) dt \right)^2, \end{aligned}$$

on approchant l'intégrale $\int_0^1 X_i(t) \widehat{v}_j(t) dt$ on a $\forall w \in \{1, \dots, k\} \ t_w = \frac{w}{k}$

$$\int_0^1 X_i(t) \widehat{v}_j(t) dt \approx \frac{1}{k} \sum_{w=1}^k X_i(t_w) \widehat{v}_j(t_w)$$

on a alors :

$$\begin{aligned} D_{\mathbf{n}} &\approx \frac{1}{\widehat{\sigma}^2 n^N} \sum_{j=1}^{Q_{\mathbf{n}}} \widehat{\lambda}_j^{-1} \left(\sum_{\mathbf{i} \in I_n} Y_{\mathbf{i}}^{\widehat{M}} \frac{1}{k} \sum_{w=1}^k X_i(t_w) \widehat{v}_j(t_w) \right)^2 \\ &\approx \frac{1}{\widehat{\sigma}^2 n^N k^2} \left(\sum_{\mathbf{i} \in I_n} Y_{\mathbf{i}}^{\widehat{M}} \sum_{w=1}^k X_i(t_w) \widehat{v}_j(t_w) \right)^2 \end{aligned}$$

$$D_{\mathbf{n}} \approx \frac{1}{\widehat{\sigma}^2 n^N k^2} \left(\sum_{\mathbf{i} \in I_n} Y_{\mathbf{i}}^{\widehat{M}} \sum_{w=1}^k X_i(t_w) \widehat{v}_j(t_w) \right)^2 \quad (3.14)$$

D'autre part, la statistique de test $S_{\mathbf{n}}$ est déduit telle que :

$$S_{\mathbf{n}} = \frac{1}{\sqrt{Q_{\mathbf{n}}}} \left(\frac{1}{\widehat{\sigma}^2} \|n^{N/2} \overline{\Delta}_{\mathbf{n}} \widehat{B}_{\mathbf{n}}\|_{\mathcal{HS}}^2 - Q_{\mathbf{n}} \right)$$

$$S_{\mathbf{n}} \approx \frac{1}{\sqrt{Q_{\mathbf{n}}}} \left(\frac{1}{\widehat{\sigma}^2 n^N k^2} \left(\sum_{\mathbf{i} \in I_n} Y_{\mathbf{i}}^{\widehat{M}} \sum_{w=1}^k X_i(t_w) \widehat{v}_j(t_w) \right)^2 - Q_n \right) \quad (3.15)$$

où

$$\begin{aligned} \overline{\Delta}_{\mathbf{n}} x &= \frac{1}{n^N} \sum_{\mathbf{i} \in I_n} Y_{\mathbf{i}}^{\widehat{M}} \langle X_i, x \rangle_G x \in G, \\ &= \frac{1}{n^N} \sum_{\mathbf{i} \in I_n} Y_{\mathbf{i}}^{\widehat{M}} \int_0^1 X_i(t) x(t) dt \end{aligned}$$

on approchant l'intégrale $\int_0^1 X_i(t) x(t) dt \quad \forall u \in (1, \dots, b)$ tel que $t_u = \frac{u}{b} \int_0^1 X_i(t) x(t) dt \approx \frac{1}{b} \sum_{u=1}^b X_i(t_u) x(t_u)$

$$\overline{\Delta}_{\mathbf{n}} x \approx \frac{1}{n^N b} \sum_{\mathbf{i} \in I_n} Y_{\mathbf{i}}^{\widehat{M}} \sum_{u=1}^b X_i(t_u) x(t_u)$$

d'autre part on a :

$$\Gamma_n = \frac{1}{n^N} \sum_{\mathbf{i} \in I_n} X_{\mathbf{i}} \otimes X_{\mathbf{i}},$$

soit $l = 1, \dots, p$ et $h \in G$

$$\begin{aligned} \Gamma_n(h)(t_l) &= \frac{1}{n^N} \sum_{\mathbf{i} \in I_n} ((X_{\mathbf{i}} \otimes X_{\mathbf{i}})h)(t_l), \\ &= \frac{1}{n^N} \sum_{\mathbf{i} \in I_n} \langle X_i, h \rangle_G X_i(t_l) \\ &\approx \frac{1}{n^N p} \sum_{\mathbf{i} \in I_n} \sum_{k=1}^p X_i(t_k) h(t_k) X_i(t_l). \end{aligned}$$

$$\begin{aligned}
\widehat{B}_n(\cdot) &= \sum_{j=1}^{Q_n} \widehat{\lambda}_j^{-1/2} \langle \widehat{v}_j, \cdot \rangle_G \widehat{v}_j, x \in G \\
&= \sum_{j=1}^{Q_n} \widehat{\lambda}_j^{-1/2} \langle \widehat{v}_j, x \rangle_G \widehat{v}_j \\
&= \sum_{j=1}^{Q_n} \widehat{\lambda}_j^{-1/2} \int_0^1 x(t) \widehat{v}_j(t) \widehat{v}_j \\
&\approx \frac{1}{s} \sum_{j=1}^{Q_n} \sum_{m=1}^s \widehat{\lambda}_j^{-1/2} x(t_m) \widehat{v}_j(t_m) \widehat{v}_j
\end{aligned}$$

les $\widehat{\lambda}_j$ sont les valeurs propres de l'opérateur de covariance empirique Γ_n associée aux fonctions propres $\widehat{v}_j$. on suppose que $Q_n < n^N, Q_n \rightarrow +\infty$ lorsque $n \rightarrow +\infty$. De plus, la norme d'Hilbert-Schmidt de l'opérateur O est donnée par : $\|O\|_{\mathcal{HS}}^2 = \langle O, O \rangle_{\mathcal{HS}} = \sum_{j=1}^{+\infty} \langle Ov_j, Ov_j \rangle_G$, où les fonctions v_j sont les fonctions propres de l'opérateur de covariance $\Gamma = \mathbb{E}[X \otimes X]$, et $\otimes$ désigne le produit tensoriel définie par : $(u \otimes v)h = \langle u, h \rangle_G v$. Ces fonctions propres v_j correspondent aux valeurs λ_j de l'opérateur Γ .

Les données $\{(X_{i_l}, Y_{i_l})\}_{1 \leq l \leq n^N}$ sont obtenus en arrangeant les sites spatiaux dans l'ordre **lexicographique** c'est-à-dire $(i_1, \dots, i_d) < (j_1, \dots, j_d) \iff \exists l \in \{1, \dots, d\}, i_1 < j_1$ où $i_k = j_k \forall k < l$ et $i_l < j_l$.

L'estimateur empirique de la variance est exprimé comme :

$$\begin{aligned}
\widehat{\sigma}^2 &= \frac{1}{tr(I - S)} \sum_{l=1}^{n^N} (Y_{i_l}^{\widehat{M}} - \langle \widehat{\Psi}, X_{i_l} \rangle)^2 \\
&= \frac{1}{tr(I - S)} \sum_{l=1}^{n^N} (Y_{i_l}^{\widehat{M}} - \int_0^1 \widehat{\Psi}(t) X_{i_l}(t) dt)^2
\end{aligned}$$

on approche l'intégrale $\int_0^1 \widehat{\Psi}(t) X_{i_l}(t) dt$ par la méthode des rectangles telle que : $\forall a \in (1, \dots, q), t_a = \frac{a}{q}$

$$\int_0^1 \widehat{\Psi}(t) X_{i_l}(t) dt \approx \frac{1}{q} \sum_{a=1}^q \widehat{\Psi}(t_a) X_{i_l}(t_a)$$

on obtient ainsi que :

$$\widehat{\sigma}^2 \approx \frac{1}{tr(I - S)} \sum_{l=1}^{n^N} \left(Y_{i_l}^{\widehat{M}} - \frac{1}{q} \sum_{a=1}^q \widehat{\Psi}(t_a) X_{i_l}(t_a) \right)^2 \quad (3.16)$$

où $\widehat{\Psi}$ est l'estimateur de Ψ déterminé en (3.17) et I est la matrice identité, S est la matrice de projection (souvent appelée matrice "chapeau"), $tr(x)$ représente la trace de matrice de x .

Pour l'estimation de la fonction de la pente Ψ , On suppose que les fonctions aléatoires X_i sont observées de manière p équidistants $t_1, \dots, t_p \in I := [1, 0]$, avec $t_j = \frac{j}{p} \forall j = 1, \dots, p$.

Soit $\mathbf{Y}^{\widehat{M}} = (Y_{i_1}^{\widehat{M}}, \dots, Y_{i_n}^{\widehat{M}})^T$ où u^T désigne la transposé de la matrice u et on considère la matrice $\mathbf{X}$ de taille $n^N \times p$ de terme général $X_{i_i}(t_j)$ pour $i = 1, \dots, n^N, j = 1, \dots, p$. Soit $\mathbf{P}_m$ une matrice de projection de taille $p \times p$ projetant sur l'espace linéaire $\mathbf{F}_m$ défini par :

$$\mathbf{F}_m := \left\{ z = (z_1, \dots, z_p)^T \in \mathbb{R}^p \left| z_j = \sum_{\ell=1}^m \theta_{\beta, \ell} t_j^{\ell-1}, j = 1, \dots, p, \theta_{\beta, \ell} \in \mathbb{R} \right. \right\},$$

où les coefficients $\theta_{\zeta, \ell}$ sont obtenus en minimisant l'erreur quadratique :

$$\sum_{j=1}^p \left[\Psi(t_j) - \sum_{\ell=1}^m \theta_{\zeta, \ell} t_j^{\ell-1} \right]^2 = \min_{\theta_1, \dots, \theta_m} \sum_{j=1}^p \left[\Psi(t_j) - \sum_{\ell=1}^m \theta_{\ell} t_j^{\ell-1} \right]^2.$$

Soit $\mathbf{E}(\mathbf{t}) = (E_1(t), \dots, E_p(t))^T$ une base fonctionnelle de l'espace vectoriel p -dimensionnel $NM^m(t_1, \dots, t_p)$, constituée de **splines naturelles** d'ordre $2m$ avec des nœuds situés en $t_1, \dots, t_p$. Soit $\tilde{\mathbf{E}}$ la matrice $p \times p$ dont l'élément général est $E_i(t_j)$, pour $i, j = 1, \dots, p$. On considère Deux matrices $p \times p$ respectivement, $\mathbf{B}_m$ et $\mathbf{C}_m$, sont définies par :

$$\mathbf{B}_m = \tilde{\mathbf{E}}(\tilde{\mathbf{E}}^T \tilde{\mathbf{E}})^{-1} \left[\int_0^1 \mathbf{E}^{(m)}(t) \mathbf{E}^{(m)}(t)^T dt \right] (\tilde{\mathbf{E}}^T \tilde{\mathbf{E}})^{-1} \tilde{\mathbf{E}}^T,$$

où $\mathbf{E}^{(m)}(t) = (E_1^{(m)}(t), \dots, E_p^{(m)}(t))^T$, avec $E_j^{(m)}(t)$ désignant la dérivée m -ième de la fonction spline $E_j(t)$, pour tout $j = 1, \dots, p$. La matrice $\mathbf{C}_m$ est alors définie comme :

$$\mathbf{C}_m = \mathbf{P}_m + p\mathbf{B}_m.$$

on suppose que la fonction $\Psi(t)$ peut s'écrire comme une combinaison linéaire de fonctions de base $E_j(t)$ (splines d'ordre $2m$), $\Psi(t) = \sum_{j=1}^p \theta_j \mathbf{E}(t) = \mathbf{E}^T(t)\theta$, en tout points des nœuds $t_1, \dots, t_p$ $\Psi = (\Psi(t_1), \dots, \Psi(t_p))^T$ on a $\Psi = \tilde{\mathbf{E}}\theta$, où $\theta = (\theta_1, \dots, \theta_p)^T$ est une matrice de taille $1 \times p$ et $\tilde{\mathbf{E}}$ est la matrice $p \times p$ dont l'élément général est $E_i(t_j)$. L'estimation de θ est obtenue en minimisant l'erreur quadratique avec une matrice de pénalité $\mathbf{C}_m$ et de paramètre de lissage ρ sous forme matricielle telle que :

$$\min_{\theta} \left(\|\mathbf{Y}^{\widehat{M}} - \mathbf{X}\theta\|^2 + \rho\theta^T \mathbf{C}_m \theta \right)$$

$$\begin{aligned} K(\rho, \theta) &= \frac{1}{n^N p} \left(\mathbf{Y}^{\widehat{M}} - \mathbf{X}\theta \right)^T \left(\mathbf{Y}^{\widehat{M}} - \mathbf{X}\theta \right) + \rho\theta^T \mathbf{C}_m \theta \\ &= \frac{1}{n^N p} \left((\mathbf{Y}^{\widehat{M}})^T - \theta^T \mathbf{X}^T \right) \left(\mathbf{Y}^{\widehat{M}} - \mathbf{X}\theta \right) + \rho\theta^T \mathbf{C}_m \theta \\ &= \frac{1}{n^N p} \left((\mathbf{Y}^{\widehat{M}})^T \mathbf{Y}^{\widehat{M}} - (\mathbf{Y}^{\widehat{M}})^T \mathbf{X}\theta - \theta^T \mathbf{X}^T \mathbf{Y}^{\widehat{M}} + \theta^T \mathbf{X}^T \mathbf{X}\theta \right) + \rho\theta^T \mathbf{C}_m \theta \\ &= \frac{1}{n^N p} \left((\mathbf{Y}^{\widehat{M}})^T \mathbf{Y}^{\widehat{M}} - 2\theta^T \mathbf{X}^T \mathbf{Y}^{\widehat{M}} + \theta^T \mathbf{X}^T \mathbf{X}\theta \right) + \rho\theta^T \mathbf{C}_m \theta, \end{aligned}$$

le minimum est atteint en zéro, en dérivant par rapport à θ on a :

$$\begin{aligned}
\frac{\partial K(\rho, \theta)}{\partial \theta} &= \frac{1}{n^N p} \left(-2\mathbf{X}^T \mathbf{Y}^{\widehat{M}} + 2\mathbf{X}^T \mathbf{X} \theta \right) + 2\rho \mathbf{C}_m \theta = 0 \\
\frac{1}{n^N p} \mathbf{X}^T \mathbf{X} \theta - \frac{1}{n^N p} \mathbf{X}^T \mathbf{Y}^{\widehat{M}} + \rho \mathbf{C}_m \theta &= 0 \\
\frac{1}{n^N p} \mathbf{X}^T \mathbf{X} \theta + \rho \mathbf{C}_m \theta &= \frac{1}{n^N p} \mathbf{X}^T \mathbf{Y}^{\widehat{M}} \\
\left(\frac{1}{n^N p} \mathbf{X}^T \mathbf{X} + \rho \mathbf{C}_m \right) \theta &= \frac{1}{n^N p} \mathbf{X}^T \mathbf{Y}^{\widehat{M}} \\
\left(\frac{1}{n^N p} \mathbf{X}^T \mathbf{X} + \rho \mathbf{C}_m \right) \theta &= \frac{1}{n^N p} \mathbf{X}^T \mathbf{Y}^{\widehat{M}} \\
\left(\frac{1}{n^N p} \mathbf{X}^T \mathbf{X} + \rho \mathbf{C}_m \right) \theta &= \frac{1}{n^N p} \mathbf{X}^T \mathbf{Y}^{\widehat{M}}
\end{aligned}$$

on a alors :

$$\widehat{\theta} = \frac{1}{n^N p} \left(\frac{1}{n^N p} \mathbf{X}^T \mathbf{X} + \rho \mathbf{C}_m \right)^{-1} \mathbf{X}^T \mathbf{Y}^{\widehat{M}}$$

Ainsi l'estimation de $\widehat{\Psi}$ aux points observés est :

$$\widehat{\Psi} = \frac{1}{n^N p} \tilde{\mathbf{E}} \left(\frac{1}{n^N p} \mathbf{X}^T \mathbf{X} + \rho \mathbf{C}_m \right)^{-1} \mathbf{X}^T \mathbf{Y}^{\widehat{M}}$$

Ainsi Ψ est obtenue par la méthode des moindres carrés pénalisés des coefficients de vecteur $\Psi = \left(\widehat{\Psi}(t_1), \dots, \widehat{\Psi}(t_p), \right)$ dans la base de spline naturelle est donner par :

$$\widehat{\Psi}(t) = \mathbf{E}(\mathbf{t})^T \left(\tilde{\mathbf{E}}^T \tilde{\mathbf{E}} \right)^{-1} \tilde{\mathbf{E}}^T \widehat{\Psi} \quad (3.17)$$

Le choix du paramètre de lissage ρ est crucial, car il influence significativement la performance des estimateurs régularisés dans la plupart des méthodes de lissage. Dans cet article, en pratique la validation croisée généralisée est utilisée et donner par :

$$GCV(\rho) = \frac{\left(\mathbf{Y}^{\widehat{M}} - \mathbf{H}_\rho \mathbf{Y}^{\widehat{M}} \right)^T \left(\mathbf{Y}^{\widehat{M}} - \mathbf{H}_\rho \mathbf{Y}^{\widehat{M}} \right)}{n^N (1 - n^{-N} Tr(\mathbf{H}_\rho))}$$

où

$$\begin{aligned}
\mathbf{H}_\rho \mathbf{Y}^{\widehat{M}} &= \mathbf{X} \widehat{\Psi} \\
\mathbf{H}_\rho \mathbf{Y}^{\widehat{M}} &= \frac{1}{n^N p} \mathbf{X} \left(\frac{1}{n^N p} \mathbf{X}^T \mathbf{X} + \rho \mathbf{C}_m \right)^{-1} \mathbf{X}^T \mathbf{Y}^{\widehat{M}} \\
\mathbf{H}_\rho &= \frac{1}{n^N p} \mathbf{X} \left(\frac{1}{n^N p} \mathbf{X}^T \mathbf{X} + \rho \mathbf{C}_m \right)^{-1} \mathbf{X}^T.
\end{aligned}$$

3.2.2 Prediction des sites non visités

Dans cette section, les auteurs effectuent une prédiction a un site non visité lorsque l'hypothèse H_0 est rejeté c'est à dire il existe une fonction $\Psi \in G = L^2([0, 1])$ telle que $\Psi \neq 0$. L'estimation de la fonction de pente a été déjà déterminer, dans ce cas, on considère deux prédictions $\widehat{Y}_{i_0}^M$ et $Y_{i_0}^{*M}$ respectivement empirique et théorique pour un site non visité $i_0 \in \mathbb{N}^N$ tel que $(X_{i_0}, Y_{i_0}^M)$ à la même distribution que (X, Y^M) , définies par :

$$\widehat{Y}_{i_0}^M = \langle \widehat{\Psi}, X_{i_0} \rangle \text{ et } Y_{i_0}^{*M} = \langle \Psi, X_{i_0} \rangle, \quad (3.18)$$

où le site non visité i_0 est tel que $\delta(\{i_0\}, I_n) \geq \left\lfloor n^{\frac{4N}{\theta}} \right\rfloor$. Pour effectuer une prédiction sur n'importe quel **site non visité il suffit de choisir un θ suffisamment grand**. Par conséquent, on considère La semi-norme $\|\cdot\|_\Gamma$ définie par :

$$\|u\|_\Gamma^2 := \langle \Gamma u, u \rangle, \quad u \in L^2([0, 1]), \quad (3.19)$$

et la semi-norme empirique discrétisée, définie pour tout $u \in \mathbb{R}^p$ par :

$$\|u\|_{\Gamma_{n,p}}^2 := \frac{1}{p} \mathbf{u}^T \left(\frac{1}{n^N p} \mathbf{X}^T \mathbf{X} \right) \mathbf{u}. \quad (3.20)$$

3.3 Résultats

Dans cette section, sous certaines hypothèses les résultats ont été reporter dans cet article.

Le lemme suivant établit la convergence presque sûre de la fonction de distribution empirique associée à la variable de censure.

Lemme 1. *Sous H_0 et certaines hypothèses, $\forall s \in \mathbb{R}$, on a :*

$$|\widehat{M}_c(s) - M_c(s)| = O_{a.s} \left(\frac{1}{n^N} \right).$$

Le lemme suivant fournit une borne supérieure négligeable pour la variance de l'erreur due à la censure.

Lemme 2. *Sous certaines hypothèses et sous l'hypothèse $H_0, \forall x \in G$, pour n assez grand on a :*

$$\text{Var} \left(\left\langle \frac{1}{n^{N/2}} \sum_{i \in I_n} (Y_i^{\widehat{M}} - Z_i) X_i, x \right\rangle_{HS} \right) = o(1)$$

Le lemme ci-dessous établit la convergence de l'opérateur de covariance croisée entre les variables d'intérêt.

Lemme 3. *Sous certaines hypothèses et sous $H_0, \forall x \in G$ on a :*

$$Var(\langle n^{N/2} \overline{\Delta_n} \rangle_{HS}) \rightarrow \sigma^2 \sum_{j=1}^{+\infty} \lambda_j \langle v_j, x \rangle_G^2 = \langle \sigma^2 \Gamma_x, x \rangle_G \text{ lorsque } n \rightarrow +\infty$$

.

Le résultat suivant établit la normalité asymptotique de l'opérateur de covariance croisée.

Théorème 2. *Sous certaines hypothèses et sous H_0 , on a :*

$$n^{N/2} \overline{\Delta_n} \xrightarrow{D} \mathcal{N}(0, \sigma^2 \Gamma)$$

où $\xrightarrow{D}$ désigne la convergence en distribution.

Le corollaire suivant fournit une approximation de la distribution de la statistique de test définie à la section 2.

Corollaire 3. *Sous les hypothèses du théorème 1, on a :*

$$D_n \overset{D}{\approx} \chi^2(Q_n)$$

où $\chi^2(Q_n)$ désigne la loi du chi-deux à Q_n degrés de liberté.

Le théorème suivant établit la normalité asymptotique de la statistique de test définie dans la section 2.

Théorème 3. *Sous certaines hypothèses et sous l'hypothèse H_0 on a :*

$$\mathbf{S}_n \xrightarrow{D} \mathcal{N}(0, 2)$$

Le résultat suivant établit la consistance du test basé sur $\mathbf{S}_n$.

Théorème 4. *Supposons que certaines Hypothèses soient vérifiées, avec $\lambda_j = O(r^j)$, pour un $0 < r < 1$, et $j \geq 1$. Alors, le test basé sur la statistique $\mathbf{S}_n$ est consistant.*

Le théorème suivant fournit une borne supérieure sur la variance de l'estimateur. Ici, $\mathbb{E}_\xi$ désigne l'espérance conditionnelle sachant $\mathbf{X}_{i_1}, \dots, \mathbf{X}_{i_N}$.

Théorème 5. *Sous certaines hypothèses, $\forall \rho > n^{-2mN}$, si les valeurs propres $\lambda_{x,1} \geq \lambda_{x,2}, \dots, \lambda_{x,p} \geq 0$ de l'opérateur de covariance empirique $\Gamma_{n,p} = \frac{1}{n^N p} \mathbf{X}^T \mathbf{X}$ vérifiant $\sum_{j=\lfloor \rho^{-1/(2m+2q+1)} \rfloor + 1}^p \lambda_{x,j} \geq D \cdot \lfloor \rho^{-1/(2m+2q+1)} \rfloor^{-2q}$ avec $D > 0$ et $q > 0$, alors*

$$\mathbb{E}_\xi(\|\widehat{\Psi} - \mathbb{E}_\xi(\widehat{\Psi})\|_{\Gamma_{n,p}}^2) \leq \frac{d}{n^N} (m + \lfloor \rho^{-1/(2m+2q+1)} \rfloor (2 + D \cdot D_0))$$

où $\|\widehat{\Psi} - \mathbb{E}_\xi(\widehat{\Psi})\|_{\Gamma_{n,p}}^2 := \frac{1}{p} \left(\widehat{\Psi} - \mathbb{E}_\xi(\widehat{\Psi}) \right)^T \left(\frac{1}{n^N p} \mathbf{X}^T \mathbf{X} \right) \left(\widehat{\Psi} - \mathbb{E}_\xi(\widehat{\Psi}) \right)$ et $D_0 > 0, d > 0$, $\lfloor x \rfloor$ désigne la partie entière de x .

En utilisant le théorème 4, on obtient le corollaire suivant.

Corollaire 4. *Sous les hypothèses du théorème 4 et sous certaines hypothèses, telle que $n^N p^{-2k} = O(1)$, $\rho \rightarrow 0$, $1/(n^{N\rho}) \rightarrow 0$ lorsque $n, p \rightarrow \infty$ on a :*

$$\|\widehat{\Psi} - \Psi\|_{\Gamma}^2 = O_p \left(\rho + (n^N \rho^{1/(2m+2q+1)})^{-1} + n^{-N(2q+1)/2} \right).$$

où $\|\widehat{\Psi} - \Psi\|_{\Gamma}^2 := \langle \Gamma \langle (\widehat{\Psi} - \Psi) \rangle, \widehat{\Psi} - \Psi \rangle$.

Le théorème suivant fournit une borne sur l'erreur quadratique de prédiction entre $\widehat{Y}_{i_0}^M$ et $Y_{i_0}^{*M}$

Théorème 6. *Supposons que les conditions du Corollaire 2 soient vérifiées, avec $\alpha_{1,\infty}(u) = O(u^{-\theta})$, $\theta > N$.*

Si $2q \geq 1$, $\rho \sim n^{-N(2m+2q+1)/(2m+2q+2)}$, et p est choisi suffisamment grand par rapport à n^N , alors :

$$\mathbb{E} \left[\left(\widehat{Y}_{i_0}^M - Y_{i_0}^{*M} \right)^2 \right] = O \left(n^{-N(2m+2q+1)/(2m+2q+2)} \right).$$

CHAPITRE 4 Classification non paramétrique
de données fonctionnelles spatiales sous censure aléatoire

Sommaire

4.1	Introduction	27
4.2	Modèle de régression et construction du classificateur	28
4.3	Méthodologie	29
4.4	Étude Numerique	32
4.4.1	Échantillon	32
4.4.2	Hypothèse de simulation	33
4.4.3	Interprétation des trois figures obtenues	33
4.4.4	Choix des paramètres optimaux	34
4.5	Résultats des simulations	36
4.6	Conjecture	37
4.7	Conclusion	37

4.1 Introduction

Le problème classique de la classification supervisée, ou discrimination, consiste à prédire la nature inconnue d'un objet pouvant prendre deux valeurs, par exemple : absence ou présence, terre cultivable ou non, que l'on note respectivement 0 ou 1 dans un cadre binaire. Dans le cas de la drépanocytose, on peut ainsi attribuer à un patient une classe correspondant à la présence ou l'absence d'une crise de la maladie.

Notre objectif est d'étudier la consistance de l'estimateur du classificateur de Bayes $f_n(x)$, à partir d'une estimation $r_n(x)$ de la fonction de régression $r(x)$, définie sous censure aléatoire (voir 4.5), et obtenue par la méthode des k plus proches voisins. Nous nous intéressons plus particulièrement aux propriétés asymptotiques de l'estimateur de l'erreur de classification de Bayes :

- consistance faible si $\lim_{n \rightarrow +\infty} \mathbb{E}[L_n] = L$;
- consistance forte si $\mathbb{P}(\lim_{n \rightarrow +\infty} L_n = L) = 1$,

où L_n désigne l'estimateur de L , l'erreur de Bayes.

La littérature abondante sur ce problème témoigne de son intérêt. Pour les données non spatiales, [15] ont étudié la consistance de la règle des k plus proches voisins pour des données fonctionnelles. Ces résultats ont été étendus au cas spatial par [2], dans le cadre de la classification non paramétrique avec données de substitution.

De même, [16] ont proposé un modèle de régression fonctionnelle sous censure aléatoire pour des patients atteints d'Alzheimer, dans un contexte de dépendance des données. Ce travail a ensuite été généralisé au cadre spatial par [3].

Par ailleurs, [9] ont abordé la classification par intelligence artificielle (IA) pour modéliser les données de patients drépanocytaires en Arabie Saoudite orientale. Cependant, malgré ces avancées récentes en IA, à notre connaissance, le cas des données spatiales avec censure aléatoire n'a pas encore été étudié.

Le reste du chapitre est organisé comme suit : la section 4.2 introduit le modèle de régression non paramétrique sous censure et la construction du classificateur. La section 4.3 présente la méthodologie en deux étapes : la substitution des données censurées par l'approche des données synthétiques, puis l'estimation de la fonction de régression par les k plus proches voisins. La section 4.4 est consacrée à une étude numérique sur données simulées afin d'évaluer les performances de l'estimateur proposé. La section 4.4.2 décrit les hypothèses de simulation, la section 4.6 expose une conjecture, et la section 4.7 conclut le chapitre.

4.2 Modèle de régression et construction du classificateur

soit $(Y_i, X_i)_{i \in I_n}$ un échantillon spatial, où $n = (n_1, \dots, n_d)$, $I_n = \{\mathbf{i} = (i_1, \dots, i_d) \in \mathbb{N}^d : 1 \leq i_\ell \leq n_\ell, \ell = 1, \dots, d\}$ est une grille spatiale, Y_i est une variable aléatoire réelle et X_i est une variable aléatoire fonctionnelle définie sur $G =: L^2([0, 1])$ l'espace des fonctions de carré intégrable avec la norme $\|\cdot\|_G$ associé au produit scalaire $\langle \cdot, \cdot \rangle_G$ défini par $\langle x, y \rangle_G = \int_0^1 x(t)y(t)dt$. On suppose que (Y_i, X_i) à la même distribution (ρ, G) qu'un vecteur aléatoire (Y, X) , où $\rho(A) = \mathbb{P}(X \in A)$ est la mesure de probabilité pour tout borélien $A \in G$. Cependant, dans la pratique certaines observations de la variable Y_i ne sont pas toutes disponibles en présence de la censure aléatoire. Soit $C_i, \mathbf{i} \in I_n$, des variables aléatoires censurées à droite, On suppose que $\{Y_i, \mathbf{i} \in I_n\}$ et $\{C_i, \mathbf{i} \in I_n\}$ sont indépendantes. Les données censurées à droite sont les paires $\{Z_i, \delta_i\}_{i \in I_n}$ définie par :

$$Z_i = \min \{Y_i, C_i\}, \delta_i = \mathbb{1}_{Y_i \leq C_i} \quad (4.1)$$

où δ_i est l'indicateur de censure.

Nous définissons notre modèle de régression sous censure aléatoire est défini telle que :

$$Z = r(X) + \mathcal{E} \quad (4.2)$$

La performance du classificateur f est mesurée par la probabilité de la plus petite erreur

d'attribution de se tromper de classe, définie comme suit :

$$L = L(f) = \inf_{f:G \rightarrow \{0,1\}} \mathbb{P}(f(X) \neq g(Z)) \quad (4.3)$$

qui définit l'erreur de classification de Bayes, et le classificateur de Bayes qui est une application mesurable $f : G \rightarrow \{0, 1\}$ telle que :

$$f(x) = \mathbb{1}_{\{r(x) \geq \frac{1}{2}\}} \quad (4.4)$$

qui est en pratique le meilleur classificateur, où $g : \mathbb{R} \rightarrow \{0, 1\}$ est une transformation binaire de la variable aléatoire de réponse réelle de censure Z .

$r(x)$ se réécrit ainsi comme dans 4.2 le modèle de régression binaire générale sous censure aléatoire telle que :

$$r(x) = \mathbb{E}[g(Z)|X = x], \quad \forall x \in G. \quad (4.5)$$

4.3 Méthodologie

Dans cette section, nous proposons un estimateur de la fonction de régression par la méthode des k-plus proches voisins .

à cause de la censure certaines observations étant manquante Comme dans les travaux de [3] dont nous avons fait un résumé étendu au chapitre 2 ainsi que [16], ont travaillé sur les données censurées, pour la substitution des données censurées, nous utiliserons la transformation des données synthétiques définie telle que :

$$Y_i^M = \int_0^{Z_i} \frac{1}{1 - M_C(s)} ds \quad (4.6)$$

où $M_C(\cdot)$ désigne la fonction de répartition de la variable de censure C_i . Sous la transformation, on a par la suite :

$$\mathbb{E}(g(Y_i^M)|X_i(\cdot)) = \mathbb{E}(g(Y_i)|X_i(\cdot)) = \mathbb{E}(g(Z_i)|X_i(\cdot)) \quad (4.7)$$

on a que :

$$Y_i^M = \int_0^{Z_i} \frac{1}{1 - M_C(s)} ds$$

Cette transformation est strictement croissante en Z_i , elle est donc bijective. soit $\varphi(z)$ cette fonction définie

$$\varphi : [0, +\infty) \rightarrow [0, +\infty)$$

telle que :

$$\varphi(z) := \int_0^z \frac{1}{1 - M_C(s)} ds$$

en dérivant par rapport à z l'intégrale nous obtenons :

$$\frac{d}{dz} \varphi(z) = \frac{1}{1 - M_C(z)} > 0$$

alors $\varphi(z)$ est strictement croissante et continue sur $[0, +\infty)$, elle réalise une bijection et sa réciproque φ^{-1} est aussi continue et strictement croissante. Posons

$$Y_i^M = \varphi(Z_i) \quad \text{et} \quad Z_i = \varphi^{-1}(Y_i^M)$$

on a $\forall x \in \mathbb{R}$

$$\mathbb{E}(g(Y_i^M)|X_i = x) = \mathbb{E}(g(\varphi(Z_i))|X_i = x)$$

par un changement de variable posons

$$u = \varphi(Z_i) \quad \text{et} \quad Z_i = \varphi^{-1}(u)$$

en utilisant le théorème de transfert

$$\begin{aligned} \mathbb{E}[g(Y_i^M) | X_i = x] &= \int_{\mathbb{R}} g(\varphi(z)) f_{Z_i|X_i}(z | x) dz \\ &= \int_{\mathbb{R}} g(u) \cdot f_{Z_i|X_i}(\varphi^{-1}(u) | x) \cdot \left| \frac{d}{du} \varphi^{-1}(u) \right| du \end{aligned}$$

où $J = \left| \frac{d}{du} \varphi^{-1}(u) \right|$ désigne le jacobien. Ainsi donc $Y_i^M|X_i = x$ a pour densité conditionnelle

$$f_{Y_i^M|X_i}(u | x) = f_{Z_i|X_i}(\varphi^{-1}(u) | x) \cdot \left| \frac{d}{du} \varphi^{-1}(u) \right|$$

comme nous l'avons démontré dans 3.11 l'égalité suivante :

$$\mathbb{E}[Y_i^M|X_i = x] = \mathbb{E}[Y_i|X_i = x] = \mathbb{E}[Z_i|X_i = x]$$

c'est à dire

$$f_{Y_i^M|X_i}(u) = f_{Y_i|X_i}(u)$$

Ainsi nous avons $\forall x \in \mathbb{R}$:

$$\mathbb{E}[g(Y_i^M) | X_i = x] = \int_{\mathbb{R}} g(u) f_{Y_i^M|X_i}(u | x) du = \int_{\mathbb{R}} g(u) f_{Y_i|X_i}(u | x) du = \mathbb{E}[g(Y_i) | X_i = x]$$

d'où

$$\mathbb{E}(g(Y_i^M)|X_i(\cdot)) = \mathbb{E}(g(Y_i)|X_i(\cdot)) = \mathbb{E}(g(Z_i)|X_i(\cdot))$$

nous avons alors en terme d'espérance que $g(Y_i^M)$ et $g(Z_i)$ sont équivalente sachant X_i . Cependant, puisque la réponse synthétique Y_i^M dépend de la fonction de répartition de censure inconnue $M_C(\cdot)$, elle doit être estimée à partir des données. Si la variable aléatoire de censure est indépendant des covariables, l'estimateur de Kaplan-Meier est un choix approprié. Inversement, lorsque la censure dépend des covariables, un estimateur $\widehat{M}_C(s)$ peut être obtenu en utilisant le modèle de régression de Cox, sans perte de généralité, nous utiliserons un estimateur empirique de la variable de réponse substitut synthétique résultante est alors donnée par :

$$Y_i^{\widehat{M}} = \int_0^{Z_i} \frac{1}{1 - \widehat{M}_C(s)} ds. \quad (4.8)$$

Ainsi donc, notre fonction de régression binaire peut s'écrire :

$$r(x) = \mathbb{E}[\mathbb{E}(g(Z)|X, Y^{\widehat{M}})|X = x], \forall x \in G \quad (4.9)$$

On définit **un ordre lexicographique** qui est un ordre défini sur les séquences finies d'éléments d'un ensemble ordonné i.e $(i_1, \dots, i_d) < (j_1, \dots, j_d) \iff \exists l \in \{1, \dots, d\}, i_l < j_l$ où $i_k = j_k \forall k < l$ et $i_l < j_l$.

on définit

$$w_{n,i} = \frac{\mathbb{1}_{\{X_i \in B_{x,a_n}\}}}{\widehat{\mathbf{n}}\rho(B_{x,a_n})} \quad (4.10)$$

est l'approche des k-plus proches voisins pondéré, où $\mathbb{1}_A$ et $B_{x,a}$, désignent respectivement, la fonction indicatrice de A et la boule fermée de rayon $a > 0$ et de centre $x \in G$, $a_n = a_n(x) \rightarrow 0$ lorsque $\mathbf{n} \rightarrow +\infty$, on a :

$$\rho(B_{x,a_n}) \geq \sqrt{\frac{k}{\widehat{\mathbf{n}}}} \quad (4.11)$$

où k est le nombre de voisins de $x \in D_n$. L'estimation de la fonction de régression par la méthode des k-plus proches voisins à l'aide d'une pondération obtenue à partir des données de substitution synthétiques

$$D_n = \{(g(Y_{i_1}), X_{i_1}), \dots, (U(Y_{i_j}^{\widehat{M}}, X_{i_j}), X_{i_j}), \dots, (g(Y_{i_{n_d}}), X_{i_{n_d}})\}.$$

où

$$U(Y_{i_j}^{\widehat{M}}, X_{i_j}) = \mathbb{E}(g(Z)|X, Y^{\widehat{M}})$$

comme $U(.,.)$ est inconnue, cela veut dire que l'estimateur $\widehat{r}_n(x)$ ne peut être utilisé comme estimateur de $r(x)$ [8]. Nous estimons alors $U(Y_{i_j}^{\widehat{M}}, X_{i_j})$ par une pondération du noyau telle que :

$$U_n(Y_{i_j}^{\widehat{M}}, X_{i_j}) = \sum_{i_l \in \mathbf{V}} g(Y_{i_l}) W_{2,n,i_l}(Y_{i_j}^{\widehat{M}}, X_{i_j}), \forall j \in \tilde{V} \quad (4.12)$$

$$= \sum_{i_l \in \mathbf{V}} g(Y_{i_l}) \left(\frac{\mathbb{1}_{\{X_{i_l} \in B_{X_{i_j}, a_n}\}} K\left(\frac{Y_{i_l} - Y_{i_j}^{\widehat{M}}}{h}\right)}{\sum_{i_l \in \mathbf{V}} \mathbb{1}_{\{X_{i_l} \in B_{X_{i_j}, a_n}\}} K\left(\frac{Y_{i_l} - Y_{i_j}^{\widehat{M}}}{h}\right)} \right) \quad (4.13)$$

où $\mathbf{V} \cup \tilde{V} = \mathcal{I}_n$, $\mathbf{V} \cap \tilde{V} = \emptyset$, $\tilde{V}$ est le complémentaire de $\mathbf{V}$, $m = \text{Card}(\mathbf{V})$, $h = h_n \searrow 0$ lorsque $\mathbf{n} \rightarrow +\infty$ {i.e., $\min_{l=1, \dots, d} \{n_l\} \rightarrow +\infty$ } h est la fenêtre, K est le noyau à support compact, $\mathbb{1}_A$ et $B_{x,a}$, sont respectivement, la fonction indicatrice de A et la boule fermée de rayon $a > 0$ et de centre $x \in G$, et $\widehat{\mathbf{n}} = n_1 \times \dots \times n_d$.

Ainsi donc on a :

$$\widehat{r}_n(x) = \sum_{i_l \in V} g(Y_{i_l}) w_{n,i_l} \delta_{i_l} + \sum_{i_j \in \widehat{V}} U(Y_{i_j}^{\widehat{M}}, X_{i_j}) w_{n,i_j} (1 - \delta_{i_j}) \quad (4.14)$$

$$= \frac{1}{\rho(B_{x,a_n}) \widehat{\mathbf{n}}} \sum_{i_l \in V} g(Y_{i_l}) \mathbb{1}_{\{X_{i_l} \in B_{x,a_n}\}} \delta_{i_l} + \frac{1}{\rho(B_{x,a_n}) \widehat{\mathbf{n}}} \sum_{i_j \in \widehat{V}} U(Y_{i_j}^{\widehat{M}}, X_{i_j}) \mathbb{1}_{\{X_{i_j} \in B_{x,a_n}\}} (1 - \delta_{i_j}) \quad (4.15)$$

, Par la suite l'estimateur de Bayes est données en introduisant l'estimateur $r_n(x)$ obtenue par la méthode des k-plus proches voisins telle que :

$$\widehat{f}_n(x) = \mathbb{1}_{\{\widehat{r}_n(x) \geq \frac{1}{2}\}} = \begin{cases} 0 & \text{si } \widehat{r}_n(x) \leq \frac{1}{2}, \\ 1 & \text{sinon,} \end{cases} \quad (4.16)$$

et l'estimateur de son erreur de classification est déduit telle que :

$$\widehat{L}_n(x) = \mathbb{P}(\widehat{f}_n(x) \neq g(Y^{\widehat{M}})) \quad (4.17)$$

4.4 Étude Numerique

Dans cette section, nous proposons une étude numérique pour monter la consistance du classificateur de Bayes. Toutes les simulations ont été réalisée avec le logiciel **R**.

4.4.1 Échantillon

Nous considérons $d = 2$, $I_n = \{\mathbf{i} = (i_1, \dots, i_d) \in \mathbb{N}^d : 1 \leq i_\ell \leq n_\ell, \ell = 1, \dots, d\}$ pour notre grille spatiale,

Nous considérons les 19 premiers éléments de la base de Fourier $B_1, \dots, B_{19}$. pour $s = 1, \dots, 19$, nous générons un vecteur $(\xi_{(m,r),1}, \dots, \xi_{(m,r),19})^T$ avec la fonction *mvrnorm*, qui simule un vecteur aléatoire à partir d'une distribution normale $\mathcal{N}(0, \sigma_\epsilon^2 \Sigma^1)$ avec $\Sigma^1 = \lambda_s \exp(-a \|h\|_2)$ la matrice de covariance spatiale, où $a = 0.1; 200$, $\lambda_s = 1$ pour $s = 1, \dots, 19$ et $\lambda_s = 0$ pour $s \geq 20$. Notons que lorsque $a = 200$, il n'y a approximativement pas d'auto-corrélation spatiale. Le processus $\{\xi_{(m,r),s} \in \mathbb{N}^2\}$ est dit fortement corrélé lorsque $a = 1$. Pour $m, r = 1, \dots, n_1 \times n_2$ nous considérons $X_{(m,r)}(t_k) = D_{(m,r)} \times \sum_{s=1}^{19} \xi_{(m,r),s} B_s(t_k)$, où $\{B_s\}$ est définie par $B_s(t) = \sqrt{a} \sin((t - \frac{1}{2}) \frac{s\pi}{2})$ lorsque s est paire et $B_s(t) = \sqrt{a} \sin((t - \frac{1}{2}) \frac{(s-1)\pi}{2})$ lorsque s est impaire [1]. Considérons 365 points équidistants discrétisés dans $[0, 1]$, nous calculons pour chaque X en chaque $t_k = \frac{k}{p}$, $k = 1, \dots, p = 365$, et $D_{(m,r)}$ est défini par :

$$D_{(m,r)} = \frac{1}{n_1 \times n_2} \sum_{1 \leq i, j \leq n_1 \times n_2} \exp(-a \|(m, r) - (i, j)\|^2).$$

la fonction D est introduite afin d'assurer et de contrôler la condition de mélange : plus a est grand, plus la dépendance est faible Dabo et al [6]. En utilisant l'ordre lexicographique $\{(X_{i_l}, Y_{i_l})\}_{1 \leq l \leq 2}$, la matrice X peut s'écrire :

$$X = (X_{(m,r)_{i_l}}(t_k))_{(i_l, k) \in \{1, \dots, n_1 \times n_2\} \times \{1, \dots, p\}}.$$

La variable réponse Y a été généré en prenant comme opérateur de régression dans [4] dans la partie étude numérique tel que :

$$r(x) = \pi \int_0^1 x^2(t) dt$$

cette variable réponse Y a été générée en approximant numériquement l'intégrale via la méthode des rectangles telles que $Y_{i_l} = \frac{1}{365} \sum_{k=1}^{365} \mathbf{X}_{i_l}^2(t_k) + \xi_{i_l}$ où ξ_{i_l} est le bruit spatial. Sous la contrainte $Y_i \leq C_i$, La variable de censure C_i suit une loi exponentielle avec un taux de paramètre $\theta = \exp(\mu)$, la réponse du temps de survie observée est donnée par $Z_i = \min(Y_i, C_i)$. Notons que le taux de censure augmente lorsque μ diminue, pour un

même $\mu = 0.2$ nous avons obtenue 70%, 70.66%, 66%, 62%, 35%, 41% en fonction de la taille de la grille ainsi que les différents paramètres qui influence notre modèle . Pour obtenir la réponse synthétique, nous avons considéré une troncature de Z au quantile à 95% des temps observés, noté t_0 . Ainsi, la transformation 4.8 est générée uniquement sur les données censurés par une approximation de la méthode des trapèzes telle que $\widehat{Y}_i^M \approx \frac{h}{2}(f(x_0) + 2 \times \sum_{i=1}^{n-2} f(x_i) + f(x_{n-1}))$ est appliquée à $Z_i I(Z_i < t_0)$, plutôt qu'à Z lui-même. Ce type de troncature permet de gérer la queue droite de la distribution du temps de survie et est courant dans le contexte de la censure à droite aléatoire.

4.4.2 Hypothèse de simulation

le processus (X_i, Y_i) est stationnaire.

4.4.3 Interprétation des trois figures obtenues

La figure 4.1 nous montre l'aspect spatiale de la covariable $X(t)$, lorsque la portée vaut $a = 0.1$ nous voyons une échelle de couleur qui montre les niveaux de dépendance entre chaque site du bleu foncée a rouge foncée et cela montre que chaque sites est dépendant de l'autre, il y a dépendance forte entre sites et par contre lorsque la portée vaut $a = 200$ on observe aucune dépendance entre sites et que l'échelle de couleur verte est au niveau de 0, on peut donc dire lorsque $a = 200$, il n y a asymptotiquement aucune dépendance spatiale entre site .






FIGURE 4.1 – Dépendance spatiale lorsque $a=0.1$ vs $a=200$

La figure 4.2 nous montre l'aspect fonctionnel de la covariable discrétisé sur l'intervalle $[0, 1]$.

FIGURE 4.2 – Flux fonctionnel de $X(t)$

La figure 4.3 nous montre l'aspect spatial de la variable réponse Y et aussi la variance autour du bruit lorsque $\sigma = 0.1$ nous voyons que les sites sont moins bruités que lorsque $\sigma = 5$ qui subit une perturbation dont les sites sont plus bruités et les couleurs de chaque site sont plus foncées .

FIGURE 4.3 – variable réponse lorsque $\sigma=0.1$ vs $\sigma=5$

4.4.4 Choix des paramètres optimaux

Dans cette sous-section, on s'intéresse au choix des paramètres optimaux de notre estimateur $\hat{r}_n$ en tenant compte du type de dépendance ($a = 0.1, a = 200$) qui peuvent significativement influencer la qualité de l'estimateur. Pour avoir une meilleure estimation du risque, on doit construire son estimateur avec des données qui n'ont pas été utilisées pour construire $\hat{r}_n$. Pour cela, on utilise la méthode de validation croisée qui consiste à

partitionner l'échantillon en $V = 10$ blocs notés $A_1, \dots, A_{10}$. Dans la pratique, $\rho(B_{x,a_n})$ est souvent difficile à calculer ainsi, nous considérons que :

$$\rho(B_{x,a_n}) = \sqrt{\frac{k}{n_1 \times n_2}}$$

issue de l'équation 4.11 où k est le nombre de voisins de $x \in D_n$. Le rayon a_n et k sont les deux paramètres à optimiser par la validation croisée basée sur la moyenne standard d'erreur de prédiction notée :

$$CVMSEP = \frac{1}{n_1 \times n_2} \sum_{l=1}^{n_1 \times n_2} \left(g(Y_i^{\widehat{M}}) - \widehat{r}_n^{(-l)}(a_n, k) \right)^2$$

où $\widehat{r}_n^{(-l)}(a_n, k)$ désigne la prédiction de $g(Y_i^{\widehat{M}})$ sur le couple (a_n, k) , calculée sans la l -ième observation (X_i, Y_i) où $l \in \{1, \dots, V\}$, la fenêtre est prise telle que $h = (\widehat{\mathbf{n}}^{-0,2})$ Nkou [11], le nombre de voisin $k = \{5, \dots, Kmax\}$ avec $Kmax = \min(50, E[\widehat{\mathbf{n}}/3])$ où $E[x]$ est la partie entière de x , $a_n = \{0.5, \dots, 2.5\}$. Le noyau qui a été utilisé est le noyau d'Epanechnikov $K(u) = 0.75(1 - u^2)1_{[-1,1]}(u)$.

TABLE 4.1 – Résultats de validation croisée des paramètres a_n^* et k^*

σ	a	$n_1 \times n_2$	a_n^*	k^*	CV	Censure(%)
0.1	0.1	10×10	2.5	26	0.22	70
		15×20	2.5	50	0.25	70.66
	200	10×10	0.5	8	0	35
		15×20	0.8	8	0	41
5	0.1	10×10	2.5	32	0.24	66
		15×20	2.5	50	0.26	62
	200	10×10	0.5	8	0.23	56
		15×20	0.5	8	0.23	50.33

* k^* : paramètre k optimal, a_n^* : paramètre a_n optimal, CV : erreur de validation croisée.

Le tableau suivant illustre les résultats obtenue de la validation croisée en tenant compte de la dépendance spatiale, ainsi que la variance autour du bruit σ .

Lorsque le bruit est faible, $\sigma = 0.1$, et que la dépendance spatiale est forte, $a = 0.1$, le rayon optimal reste constant, $a_n^* = 2.5$, quelle que soit la taille de l'échantillon, tandis que le nombre de plus proches voisins varie entre $k^* = 26$ et $k^* = 50$.

Dans cette configuration, l'erreur de validation croisée demeure faible, $CV \approx 0.22-0.25$, ce qui traduit une bonne capacité de généralisation du modèle. Le taux de censure, quant à lui, présente de légères variations selon la taille de l'échantillon.

Par ailleurs, lorsque le bruit est plus fort, $\sigma = 5$, avec une dépendance spatiale marquée, $a = 0.1$, le rayon optimal reste inchangé, $a_n^* = 2.5$, mais le nombre de voisins augmente légèrement, $k^* = 32-50$, lorsque la taille de l'échantillon croît. L'erreur de validation croisée,

CV, est alors plus élevée que dans le cas du bruit faible, traduisant l'effet perturbateur du bruit sur la précision du modèle.

Enfin, lorsque la dépendance spatiale est faible, $a = 200$, sous un bruit fort, le rayon demeure petit, $a_n^* = 0.5$, et le nombre de voisins reste stable, $k^* = 8$, ce qui confirme que, dans un contexte de faible corrélation spatiale, l'influence du bruit reste limitée sur le choix des paramètres optimaux.

4.5 Résultats des simulations

L'efficacité de l'estimateur de l'erreur de classification de Bayes est évaluée par l'erreur quadratique moyen (EQM) [Dabo et al \[7\]](#) telle que :

$$EQM(\hat{L}_n(x)) = \frac{1}{n_1 \times n_2 \times M} \sum_{i=1}^{n_1 \times n_2} \sum_{m=1}^{M=300} \left(L(x_i) - \hat{L}_n(x_i)^{[m]} \right)^2 \quad (4.18)$$

où $\hat{L}_n(x_i)^{[M]}$ est l'estimateur de $L(x_i)$ calculée (à partir de la m-ième réplication de la procédure de Monte-Carlo) au covariable $x_i, i = 1, \dots, n_1 \times n_2$. Dans le cadre de notre travail nous avons effectué 300 réplifications de Monte-Carlo. Le tableau ci-dessous nous donne les différents résultats de l'EQM en tenant compte du type de dépendance ($a=0.1, a=200$) ainsi que la variance σ

TABLE 4.2 – Résultats de l'EQM pour $\sigma = 0.1$ et $\sigma = 5$ avec deux valeurs de a

σ	a	$n_1 \times n_2$	EQM
0.1	0.1	10×10	0.44966
		15×20	0.51342
	200	10×10	0
		15×20	0
5	0.1	10×10	0.47243
		15×20	0.50557
	200	10×10	0.46233
		15×20	0.47055

* EQM : erreur quadratique moyenne.

lorsque $\sigma = 0.1$ c'est-à-dire avec un bruit faible autours de la variance et que $a = 0.1; a = 200$ et en tenant compte de la taille d'échantillon l'erreur quadratique moyen de $\hat{L}_n$ converge respectivement, l'une des particularités observées avec une dépendance faible de $a = 200$ l'erreur quadratique moyen de $\hat{L}_n$ converge vers L . D'autre part lorsque $\sigma = 5$ c'est-à-dire avec un bruit fort autours de la variance avec $a = 0.1, a = 200$ et en tenant compte de la taille d'échantillon l'erreur quadratique moyen de $\hat{L}_n$ converge respectivement L .

Ces résultats obtenus traduisent en fonction de la dépendance spatiale ($a = 0.1, a = 200$) et de la variance autours du bruit la consistance de l'estimateur d'erreur du classificateur de bayes $\hat{L}_n(x_i)$ qui converge vers sa vraie valeur L .

4.6 Conjecture

Sous l'hypothèse de simulation, l'estimateur $\hat{L}_n(x)$ est consistant.

4.7 Conclusion

En considérant, les résultats obtenus par replication de Monte-carlo de l'erreur quadratique moyen de l'estimateur de l'erreur du classificateur de Bayes ,et tenant compte de la dependance spatiale (a=0.1,a=200) et de la variance autour du bruit,notre estimateur est consistant.

Conclusion et Perspectives

Dans ce cette partie, nous rappelons les grandes lignes de notre travail et nous précisons quelques perspectives que nous envisageons.

Conclusion

Au terme de notre travail, nous avons proposé une méthodologie de classification non paramétrique adapté aux données fonctionnelles spatiales. Notre démarche s'est articulé sur trois étapes essentielles :

- une transformation de la données synthétique pour les observations censurées ainsi qu'une substitution par estimation noyau pondéré.
- une estimation par la méthode des k-plus proches voisins qui combine les données observées et les données substituées.

par la suite, les études numériques réalisées par simulation de Monte carlo ont permis d'illustré la consistance du classificateur de Bayes, tout en montrant l'impact de la dépendance spatiale, le choix des paramètres optimaux ainsi que la variance autour du bruit. En résumé, ce travail constitue une première contribution à l'étude de la classification non paramétrique dans un cadre spatial avec censure aléatoire.

Perspectives

Ce travail, ouvre la voie à plusieurs perspectives : par le biais de l'exploration de données réelles, il s'agira :

- de comprendre la prévalence de la drépanocytose, de déterminer les informations sur l'héritage des patients atteints par cette maladie
- d'étudier les causes d'admission et de sortie de l'hôpital en cas de crise de cette maladie
- l'amélioration des stratégies de voisinage pour optimiser la performance du classificateur.
- la conjecture obtenue par simulation de Monte-carlo sur la consistance du classificateur de Bayes doit être démontré de manière théorique
- une étude comparative avec plusieurs noyaux car nous n'avons utilisé que le noyau d'Epanichnikov.

Bibliographie

- [1] S. BOUKA, S. DABO-NIANG et G. M. NKIET, *On estimation and prediction in spatially dependent functional linear regression model*, Lithuanian Mathematical Journal, vol. 63, no. 1, pp. 13–30, 2023.
- [2] S. BOUKA, K. PAMBO BELLO, *A note on the k -nearest neighbors rule for spatial functional data in regression model with surrogate scalar response*, Far East Journal of Theoretical Statistics, vol. 68, no. 1, pp. 147–155, 2024.
- [3] S. BOUKA, P. KOWIR, *Analysis of spatial functional linear regression models under random censoring*, Preprint.
- [4] M. BOUHAHDI, I. OUASSOU et M. RACHDI, *Generalized regression function for surrogate scalar response*, Math. Model. Comput., vol. 10, pp. 625–637, 2023.
- [5] T. COVER et P. HART, *Nearest neighbor pattern classification*, IEEE Transactions on Information Theory, vol. 13, no. 1, pp. 21–27, 1967.
- [6] S. DABO-NIANG, C. TERNYNCK et A.-F. YAO, *Nonparametric prediction of spatial multivariate data*, Journal of Nonparametric Statistics, vol. 28, no. 2, pp. 428–458, 2016.
- [7] S. DABO-NIANG et A. AMIRI, *Density estimation over spatio-temporal data streams*, Econometrics and Statistics, 2017.
- [8] F. IBRAHIM, A. H. HASSAN, J. DEMONGEOT et M. RACHDI, *Regression model for surrogate data in high dimensional statistics*, Communications in Statistics-Theory and Methods, vol. 49, no. 13, pp. 3206–3227, 2020.
- [9] M. GOLLAPALLI et A. ALFALEH, *An Artificial Intelligence Approach for Data Modelling Patients Inheritance of Sick Cell Disease (SCD) in the Eastern Regions of Saudi Arabia*, Mathematical Modelling of Engineering Problems, vol. 9, no. 4, pp. 1079–1088, 2022.
- [10] M. MOKKADEM, M. DOUMA et M. PELLETIER, *Online Estimation of Hazard Rate Under Random Censoring*, Journal of Statistical Planning and Inference, vol. 196, pp. 87–104, 2018.
- [11] E. D. NKOU, *Recursive kernel estimator in a semiparametric regression model*, Journal of Nonparametric Statistics, vol. 35, no. 1, pp. 145–171, 2023.

-
- [12] A. MENAFOLGIO, P. SECCHI et M. DALLA ROSA, *A Universal Kriging predictor for spatially dependent functional data of a Hilbert Space*, Electronic Journal of Statistics, vol. 7, pp. 2209–2240, 2013.
- [13] M. IGALA, G. D. H. ONDO, L. E. LEDAGA, L. K. RERAMBIAH, S. D. LACOMBE et J. I. BA BOGUIKOUA, *Profil socio-démographique et économique des adultes drépanocytaires régulièrement suivis au Centre Hospitalier Universitaire de Libreville*, Pan African Medical Journal, vol. 41, no. 1, 2022.
- [14] E. FIX, *Discriminatory analysis : nonparametric discrimination, consistency properties*, vol. 1, USAF School of Aviation Medicine, 1985.
- [15] A. YOUNSO, *Consistency of the k -nearest neighbors rule for functional data*, C. R. Math. Acad. Sci. Paris, vol. 361, pp. 237–242, 2023.
- [16] S. J. YANG, H. SHIN, S. H. LEE et S. LEE, *Functional linear regression model with randomly censored data : Predicting conversion time to Alzheimer’s disease*, Computational Statistics & Data Analysis, vol. 150, 107009, 2020.
- [17] B. STTI et K. OHENE-FREMPONG, *Healthcare provision for sickle cell disease in Ghana : challenges for the African context*, Diversity in Health and Social Care, vol. 5, pp. 241–254, 2008.
- [18] H. ZHANG, *Topics in functional data analysis and machine learning predictive inference*, PhD Thesis, Iowa State University, 2019.

A**Annexe**

```
library(fda) ## données fonctionnelle
library(fBasics) ## base de fourier
library(fda.usc)
library(OmicsPLS)
library(fields)
library(geoR)
library(MultiRNG)
library(Matrix)

data2=function(n1,n2,a,sigma){
  set.seed(1)
  nxn <- n1*n2
  sigma2 <- sigma^2
  argvals=seq(0, 1, 1/364)## grille fonctionnelle
  p=length(argvals)
  nbasis <- 19
  ##grille spatiale
  step <- 1
  x1 <- seq(1, n1, step)
  x2 <- seq(1, n2, step)
  coordinates<-expand.grid(x1, x2) ## grille spatiale
  mean.coef <- rep(0, nxn)
  distance <- dist(coordinates)
  distsite <- as.matrix(distance)
  #Dep<-t(matrix(0, nxn, nxn))
  Dep <-exp(-a*(distsite))
  Dep <- apply(Dep, 2, mean)
  ###-----
  ###-----BASE FONCTIONNELLE-----
  ###-----
  rangeval <- range(argvals)
  bf.basis <- create.fourier.basis(rangeval, nbasis, period = diff(rangeval))
  Phi <- eval.basis(argvals, bf.basis, Lfdobj = 0)
  ###-----
  ###-----GENERATION DES DONNEES FUNCTIONNELLES-----
```

```

###-----
X <- array(0, dim = c(nxn, p))

coef_array <- matrix(0, nrow = nxn, ncol = nbasis)

for (k in 1:nbasis) {
  covariance.coef <- cov.spatial(distsite, cov.model = "exponential",
  cov.pars = c(0.5^(0.5*(k-1)), 1/a))
  covariance.coef <- as.matrix(covariance.coef) + diag(0.5^(k-1),nxn)

  coef_vect <- mvrnorm(1, mu = mean.coef,covariance.coef)
  coef_array[, k] <- coef_vect
}
x <- coef_array %*% t(Phi)
X<- Dep* x
X=matrix(X,nxn,p)
###-----
###-----EPSILON-----
###-----

covariance.coef1 <- cov.spatial(distance, cov.model="exp",cov.pars=c(sigma,1/a))

covariance.coef1 <- as.matrix(covariance.coef1)+diag(sigma2,nxn,nxn)

covariance.coef1=makePositiveDefinite(covariance.coef1)

epsilon=mvrnorm(1,mean.coef,covariance.coef1)

###-----
###-----VARIABLE--REPOSE-----
###-----
s=numeric(nxn)
for(j in 1:p){
  s=s + X[,j]*X[,j]
}
Y=pi*s/p +epsilon

C <-rexp(nxn , rate = 0.2)# Temps de censure
C <-Dep * C
Z <- pmin(Y, C) # Temps observé
delta <- as.numeric(Y <= C) # Indicateur de censure (1 = non censuré, 0 = censuré)
# Calcul du quantile pour le point de troncature t0
t0 <- quantile(Z, 0.95)
# Créer la fonction de répartition empirique
F_empirique <- ecdf(C)

```

```
# Définir l'intégrale
integrale <- function(s) {
  1 / (1 - F_empirique(s))
}

# Fonction d'intégration par la méthode des trapèzes
integrate_trapezoid <- function(func, lower, upper, n = 1000) {
  x <- seq(lower, upper, length.out = n)
  y <- func(x)
  h <- (upper - lower) / (n - 1)
  integral <- (h / 2) * (y[1] + 2 * sum(y[2:(n-1)]) + y[n])
  return(integral)
}

# Appliquer la transformation uniquement aux observations censurées
Y_G <- numeric(nxn)
for (i in 1:(nxn)) {
  top <- min(Z[i], t0)
  if (delta[i] == 0) { # Si l'observation est censurée
    Y_G[i] <- integrate_trapezoid(integrale, lower = 0, upper = top, n = 1000)
  } else { # Si l'observation n'est pas censurée
    Y_G[i] <- Y[i]
  }
}

# Vérification du pourcentage de censure
censorship_rate <- mean(delta == 0) * 100
print(paste("Pourcentage de censure :", censorship_rate, "%"))

Dn=cbind(X,Y,delta,Y_G)
return(Dn)
}

##### VALIDATION CROISEE###
vgc1 <- function(n1, n2, a, sigma) {
  don <- as.matrix(data2(n1, n2, a, sigma))
  nxn <- n1 * n2
  argvals <- seq(0, 1, 1/364)
  p <- length(argvals)
  X <- as.matrix(don[1:nxn, 1:p])
  Y <- don[1:nxn, p+1] # variable expliquée substituée
  delta <- don[1:nxn, p+2]
  Y_G <- don[1:nxn, p+3] # variable expliquée réelle

  n_folds <- 10
  rn <- seq(0.5, 2.5, length.out = 10)
  Kmax <- min(50, floor(nxn / 3))
  K <- seq(5, Kmax, by = 3)
```

```
## Fonction auxiliaire : distance
dista=function(x,y)
{
x=as.matrix(x)
y=as.matrix(y)
m1=nrow(x)
m2=nrow(y)
p=ncol(x)
D=matrix(0,m1,m2)
for(i in 1:m1){
for(j in 1:m2){
D[i,j]=sqrt(t(x[i,]-y[j,])%*(x[i,]-y[j,])/p)
}
}
D
}

## Boule fermée
ind2=function(A,B,rn){
A=as.matrix(A)
B=as.matrix(B)
rn=as.numeric(rn)
m1=nrow(A)
m2=nrow(B)
G=array(0,c(m1,m2,length(rn)))
for(i in 1:m1){
for(j in 1:m2){
for(k in 1:length(rn)){
if(dista(A,B)[i,j]>rn[k]) G[i,j,k]=0 else G[i,j,k]=1
}
}
}
G
}

## Transformation binaire
ind1 <- function(A) ifelse(abs(as.numeric(A)) > 3/2, 1, 0)

## Noyau Epanechnikov
K2 <- function(A) ifelse(abs(A) <= 1, (3/4) * (1 - A^2), 0)

## Fonction U_sub
U_sub <- function(Y_G, X, delta, rn, h) {
v <- which(delta == 1)      # non-censurés
vtilde <- which(delta == 0) # censurés
nv <- length(v)
nc <- length(vtilde)
```

```
U <- numeric(nc)
M <- matrix(0, nc, nv)

for (j in 1:nc) {
  for (l in 1:nv) {
    in_ball <- ind2(matrix(X[v[l], ], 1), matrix(X[vtilde[j], ], 1), rn)
    M[j, l] <- in_ball * K2((Y_G[v[l]] - Y_G[vtilde[j]])) / h)
    U[j] <- U[j] + ind1(Y_G[v[l]]) * M[j, l]
  }
  som <- sum(M[j, ])
  if (som > 0) {
    U[j] <- U[j] / som
  } else {
    U[j] <- 0
  }
}
return(U)
}

## Validation croisée
set.seed(123)
données <- cbind(X, Y, Y_G, delta)
dones <- données[sample(nrow(données)), ]

# extraction des variables mélangées
X <- as.matrix(dones[, 1:p])
Y <- dones[, p+1]
Y_G <- dones[, p+2]
delta <- dones[, p+3]

# découpage en folds
folds <- cut(seq(1, nrow(dones)), breaks = n_folds, labels = FALSE)

# tableau d'erreurs
erreur <- array(0, dim = c(length(rn), length(K), n_folds))

for (r_idx in 1:length(rn)) {
  rn_val <- rn[r_idx]
  for (k_idx in 1:length(K)) {
    K_val <- K[k_idx]

    for (l in 1:n_folds) {
      indices_test <- which(folds == l, arr.ind = TRUE)
      testdones <- dones[indices_test, ]
      traindones <- dones[-indices_test, ]

      # train
```

```
X_train <- traindones[, 1:p]
Y_train <- traindones[, p+1]
Y_G_train <- traindones[, p+2]
delta_train <- traindones[, p+3]

# test
X_test <- testdones[, 1:p]
Y_test <- testdones[, p+1]
Y_G_test <- testdones[, p+2]
delta_test <- testdones[, p+3]

n_train <- nrow(X_train)
n_test <- nrow(X_test)

# estimation de U
Un_hat <- U_sub(Y_G_train, X_train, delta_train, rn = rn_val, h = n_train^(-0.2))

# prédiction
pred <- numeric(n_test)
idx_V <- which(delta_train == 1)
idx_Vtilde <- which(delta_train == 0)

for (i in 1:n_test) {
  xi <- matrix(X_test[i, ], 1)
  rv <- 0
  rc <- 0

  if (length(idx_V) > 0) {
    for (a in idx_V) {
      rv <- rv + ind1(Y_G_train[a]) * ind2(matrix(X_train[a, ], 1), xi, rn_val)
    }
  }
  if (length(idx_Vtilde) > 0) {
    for (j in seq_along(idx_Vtilde)) {
      rc <- rc + Un_hat[j] * ind2(matrix(X_train[idx_Vtilde[j], ], 1), xi, rn_val)
    }
  }
  term1 <- rv / length(idx_V) * sqrt(K_val / n_train)
  term2 <- rc / length(idx_Vtilde) * sqrt(K_val / n_train)
  pred[i] <- term1 + term2
}

# stockage de l'erreur dans la bonne case
erreur[r_idx, k_idx, l] <- mean((pred - ind1(Y_G_test))^2)
}
}
}
```

```

# moyenne des erreurs
erreur_moy <- apply(erreur, c(1, 2), mean)

# meilleur couple
idx_best <- which(erreur_moy == min(erreur_moy), arr.ind = TRUE)
best_rn <- rn[idx_best[1]]
best_K <- K[idx_best[2]]
best_err <- erreur_moy[idx_best]

return(list(cv = best_err,
best_rn = best_rn,
best_K = best_K))
}

#####
Programme principale
#####
erreur_prd=function(n1,n2,a,rn,K,sigma){
don <- as.matrix(data2(n1, n2, a, sigma))
nxn <-nrow(don)
p<-ncol(don)-3
X <- as.matrix(don[, 1:p])
Y <- don[, p+1] # variable expliquée substituée
delta <- don[, p+2]
Y_G <- don[, p+3] # variable expliquée réelle
## Fonction auxiliaire : distance
dista=function(x,y)
{
x=as.matrix(x)
y=as.matrix(y)
m1=nrow(x)
m2=nrow(y)
p=ncol(x)
D=matrix(0,m1,m2)
for(i in 1:m1){
for(j in 1:m2){
D[i,j]=sqrt(t(x[i,]-y[j,])%*(x[i,]-y[j,])/p)
}
}
D
}

## Boule fermée
ind2=function(A,B,rn){
A=as.matrix(A)
B=as.matrix(B)
###rn=as.numeric(rn)
m1=nrow(A)

```

```

m2=nrow(B)
G=matrix(0,m1,m2)
for(i in 1:m1){
  for(j in 1:m2){
    if(dista(A,B)[i,j]>rn) G[i,j]=0 else G[i,j]=1
  }
}
G
}

## Transformation binaire
ind1 <- function(A) ifelse(abs(as.numeric(A)) > 3/2, 1, 0)

## Noyau Epanechnikov
K2 <- function(A) ifelse(abs(A) <= 1, (3/4) * (1 - A^2), 0)

## Fonction U_sub
U_sub <- function(Y_G, X, delta, rn, h) {
  v <- which(delta == 1)      # non-censurés
  vtilde <- which(delta == 0) # censurés
  nv <- length(v)
  nc <- length(vtilde)

  U <- numeric(nc)
  M <- matrix(0, nc, nv)

  for (j in 1:nc) {
    for (l in 1:nv) {
      in_ball <- ind2(matrix(X[v[l], ], 1), matrix(X[vtilde[j], ], 1), rn)
      M[j, l] <- in_ball * K2((Y_G[v[l]] - Y_G[vtilde[j]]) / h)
      U[j] <- U[j] + ind1(Y_G[v[l]]) * M[j, l]
    }
    som <- sum(M[j, ])
    if (som > 0) {
      U[j] <- U[j] / som
    } else {
      U[j] <- 0
    }
  }
  return(U)
}

# estimation de U
Un_hat <- U_sub(Y_G, X, delta, rn =rn , h = nxn^(-0.2))

# prédiction
pred <- numeric(nxn)
idx_V <- which(delta == 1)
idx_Vtilde <- which(delta == 0)

```

```

for (i in 1:nxn) {
x <- matrix(X[i, ], 1)
rv <- 0
rc <- 0

if (length(idx_V) > 0) {
for (a in idx_V) {
rv <- rv + ind1(Y_G[a]) * ind2(matrix(X[a, ], 1), x, rn)
}
}
if (length(idx_Vtilde) > 0) {
for (j in seq_along(idx_Vtilde)) {
rc <- rc + Un_hat[j] * ind2(matrix(X[idx_Vtilde[j], ], 1), x, rn)
}
}
term1<- rv/ length(idx_V)* sqrt(K / nxn)
term2<-rc/ length(idx_Vtilde)* sqrt(K / nxn)
pred[i] <-term1 +term2
}

###fonction de regression
O=numeric(nxn)
for(j in 1:p){
O=O + X[,j]*X[,j]
}
r=pi*O/p

##erreur de classification de Bayes theorique
K4 <-function(B) ifelse(as.numeric(B)<1/2,0,1)
##fonction difference
K5 <-function(x,y) ifelse(x!=y,1,0)
##erreur theorique du classificateur
et<- K5(K4(r),ind1(Y_G))
# erreurs individuelles empiriquede classification de Bayes (0/1)
ep <-K5(K4(pred),ind1(Y_G))
# erreur global
#err_global <- abs(ep-et)
resultat=data.frame(et,ep)
return(resultat)
}

##### Monte-carlo
MC=function(n1,n2,a,rn,K,sigma){
M=300 ##nombre de réplcation
##stockages des resultats

```

```
nxn=n1*n2
results<-matrix(0,nrow = M,ncol = nxn)
##replication
for (m in 1:M) {

results[m,<-erreur_prd(n1,n2 ,a ,rn,K ,sigma)$ep
}
return(results)
}
i=n1*n2*M
#####le MSE
MSE=sum((erreur_prd(n1,n2,a ,rn ,K,sigma )$et-t(MC(n1,n2 ,a,rn ,K,sigma)))^2)/i
```

